Laboratorium 1: Poznaj swoje dane

W ramach naszych zajęć będziemy przechodzić przez kolejne warstwy systemu NLP:

`dane → baseline → reprezentacja → transformer → IE/NER → LLM → retrieval → RAG → ewaluacja`

Ten sam sposób myślenia będzie wracał na każdych zajęciach:

1. **pytanie badawcze,**
2. **hipoteza,**
3. **eksperyment,**
4. **metryka,**
5. **analiza błędów,**
6. **wniosek.**

> **Pytanie badawcze na dziś:** zanim wybierzemy model, czy wiemy, na jakich danych będziemy go trenować i testować?

Po tych zajęciach student potrafi:

- wykonać podstawowy EDA dla danych tekstowych;
- sprawdzić rozkład klas i długości tekstów;
- wykryć puste rekordy, duplikaty (i potencjalne duplikaty);
- sprawdzić, czy między `train`, `validation` i `test` nie ma wycieku danych (data leakage);
- zbudować powtarzalny split i zapisać jego manifest;
- przygotować prostą kartę opisową zbioru;
- odróżnić problem modelu od problemu danych.

Zasada na dziś

> **Podejrzanie dobry wynik jest powodem do szczegółowej ewaluacji, nie do świętowania.**

Dane: PolEmo 2.0 / KLEJ

Pracujemy na polskich recenzjach konsumenckich z zadania PolEmo 2.0 w benchmarku KLEJ.

Klasy sentymentu:

- `plus` : pozytywny,
- `minus` : negatywny,
- `zero` : neutralny,
- `amb` : niejednoznaczny.

Repozytorium danych:
https://huggingface.co/datasets/allegro/klej-polemo2-in

Publikacja KLEJ:
https://arxiv.org/abs/2005.00630

Licencja zbioru na Hugging Face: CC BY-SA 4.0.

> **Ważne:** w projekcie produkcyjnym sprawdzamy nie tylko jakość danych, ale również ich pochodzenie, licencję, warunki redystrybucji i możliwość przetwarzania.

Ustawienia wstępne

Do laboratorium wystarczy klasyczny stack Data Science.

Jeśli pracują Państwo w izolowanym / nowym środowisku:

```
pip install pandas numpy matplotlib scikit-learn pyarrow
```

In [312…

```python
from pathlib import Path
import hashlib
import json
import re
import unicodedata

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.neighbors import NearestNeighbors
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score, classification_report

RANDOM_STATE = 42

pd.set_option("display.max_colwidth", 160)
pd.set_option("display.max_columns", 50)

ARTIFACTS = Path("artifacts")
ARTIFACTS.mkdir(exist_ok=True)
```

1. Pobranie danych

Ładujemy oficjalne splity. Podział danych jest częścią eksperymentu, a nie technicznym szczegółem.

In [313…

```python
# TODO: ładowanie splitów datasetu (pliki train.csv, valid.csv, test.csv w repozytorium HF)
#
# Po tej komórce MUSZĄ istnieć (używają ich dalsze komórki):
#   URLS        - dict: split -> URL pliku
#   splits      - dict: "train" / "validation" / "test" -> DataFrame z kolumnami text, target, split
#   train_df, val_df, test_df
#   SPLIT_SIZES - dict: split -> liczba rekordów
#   CLASSES     - lista klas
#   LABEL_MAP   - dict: oryginalna etykieta -> plus / minus / zero / amb

# Uwaga: nazwy kolumn w pliku źródłowym mogą różnić się od nazw używanych w notatniku.
```

```
URLS = {
    "train": "https://huggingface.co/datasets/allegro/klej-polemo2-in/blob/main/train.csv",
    "valid": "https://huggingface.co/datasets/allegro/klej-polemo2-in/blob/main/valid.csv",
    "test": "https://huggingface.co/datasets/allegro/klej-polemo2-in/blob/main/test.csv"
}
SPLIT_SIZES = {}
NAMES = ["text", "target"]
train_df = pd.read_csv("train.csv", names=NAMES,header=0)
valid_df = pd.read_csv("valid.csv", names=NAMES, header=0)
test_df = pd.read_csv("test.csv", names=NAMES, header=0)
splits = {"train": train_df, "valid": valid_df, "test": test_df }
LABEL_MAP = {"__label__meta_plus_m": "plus", "__label__meta_minus_m": "minus", "__label__meta_zero": "zero", "__label__meta_amb": "amb"}
CLASSES = list(LABEL_MAP.values())

SPLIT_SIZES={"train": train_df.shape[0], "valid": valid_df.shape[0], "test": test_df.shape[0]}

for name, split in splits.items():
    SPLIT_SIZES[name] = split.shape[0]
    split["split"] = name
    split["target"] = split["target"].map(LABEL_MAP)

all_df = pd.concat(splits.values(), ignore_index=True)

all_df.head()
```

Out[313…

	text	target	split
0	Super lekarz i człowiek przez duże C . Bardzo duże doświadczenie i trafne diagnozy . Wielka cierpliwość do ludzi starszych . Od lat opiekuje się moją Mamą s...	plus	train
1	Bardzo olewcze podejscie do pacjenta . Przyprowadzajac dziecko z ostra wysypka na calym ciele trwajaca od 2 tygodni Pani doktor stwierdzila ze nie widzi wsk...	minus	train
2	Lekarz zalecił mi kurację alternatywną do dotychczasowej , więc jeszcze nie daję najwyższej oceny (zobaczymy na ile okaże się skuteczna) . Do Pana doktora...	amb	train
3	" Konsumenci oczywiście kierują się ceną . Te leki są tańsze , ale dzisiaj nie możemy już powiedzieć , że znacznie tańsze . Jest to mniej krępujące , nie tr...	zero	train
4	Pani Doktor Iwona jest profesjonalistką w każdym calu :) Idąc do stomatologa zawsze czuję przeraźliwy strach . Pani Doktor Iwona jest wyrozumiała i delikat...	plus	train

In [314…

```
print(f"Train shape: {train_df.shape}, validation shape: {valid_df.shape}, test shape: {test_df.shape}")
```

```
Train shape: (5783, 3), validation shape: (723, 3), test shape: (722, 3)
```

In [315…

```
train_df.columns
```

Out[315…

```
Index(['text', 'target', 'split'], dtype='str')
```

Zadanie 1: Sanity check danych

Zanim zrobią Państwo coś bardziej zaawansowanego, proszę odpowiedzieć na pytanie:

1. Jakie kolumny zawiera zbiór?
2. Jaki jest typ każdej kolumny?
3. Czy liczba rekordów zgadza się między źródłem a tym, co faktycznie wczytaliśmy?
4. Czy występują wartości brakujące?
5. Czy etykiety mają ten sam zbiór wartości w każdym splicie? Jeśli nazwy etykiet są nieczytelne, proszę zdefiniować `LABEL_MAP` (np. `__label__meta_plus_m` → `plus`) i zapisać go w manifeście.
6. Czy są rekordy z pustym albo bardzo krótkim tekstem?

Do wykonania

Proszę uzupełnić komórkę poniżej. Wynik powinien zawierać jedną małą tabelę ewaluacyjną per split.

In [431…

```
# TODO: sanity check dla train / validation / test.
#
# Minimalne kolumny tabeli:
# - split
# - rows
# - columns
# - missing_text
# - missing_target
# - unique_labels
#
# Wskazówka:
# display(df.isna().sum())
# display(df["target"].value_counts(dropna=False))

SHORT_WORD_THRESHOLD = 20
audit_rows = []

# MIEJSCE NA KOD
for name, split in splits.items():
    audit_rows.append({
        "split": name,
        "rows": split.shape[0],
        "columns": split.shape[1],
        "missing_text": int(split["text"].isna().sum()),
        "missing_target": int(split["target"].isna().sum()),
        "unique_labels": int(split["target"].nunique()),
        "short_texts_counter": int((split["text"].str.len() < SHORT_WORD_THRESHOLD).sum())
    })

pd.DataFrame(audit_rows)
```

Out[431…

	split	rows	columns	missing_text	missing_target	unique_labels	short_texts_counter
0	train	5783	3	0	0	4	1
1	valid	723	3	0	0	4	0
2	test	722	3	0	0	4	0

In [317…

```
print(train_df[train_df["text"].str.len() < SHORT_WORD_THRESHOLD])
```

```
     text target  split
4476    P    amb  train
```

> 1. Zbiór zawiera 2 kolumny tj. **text** -> opinia użytkownika oraz **target** -> przyporządkowana klasa do opini dodatkowo dodałem kolumnę **split** informacja czy jest to opinia ze zbioru treningowego, walidacyjnego czy testowego.
> 2. Każda z kolumn jest typu `str`
> 3. Tak, liczba wczytanych rekordów zgadza się z liczbą zadeklarowaną w karcie zbioru.
> 4. Nie, w żadnym splicie nie ma ani jednej wartości pustej lub brakującej w obu kolumnach.
> 5. Tak, w każdym splicie etykiety przyjmuja następujące wartości ['minus', 'plus', 'zero', 'amb'], są to etykiety otrzymane po przez zmapowania oryginalnych według **LABEL_MAP**
> 6. Tak, w zbiorze treningowym jest jedna opinia `P`, która została przyporządkowana do klasy `amb`

Hipoteza 1

Czy dane są zbalansowane?

Zanim sporządzą Państwo wykres, proszę sformułować hipotezę.

> Spodziewam się, że **minus** będzie klasą dominującą, ponieważ **z moich własnych obserwacji wynika, że osoby sfrustrowane cześciej piszą opinie**.

Zadanie 2: Rozkład klas

Proszę policzyć:

- liczebność klas,
- udział procentowy klas,
- rozkład osobno dla `train`, `validation`, `test`.

Następnie proszę odpowiedzieć:

1. Czy accuracy będzie wystarczającą metryką na późniejszych zajęciach?
2. Jaki wynik osiągnąłby naiwny klasyfikator zawsze wybierający najczęstszą klasę?
3. Czy rozkłady klas między splitami są podobne?

In [318…

```python
# TODO: tabela rozkładu klas dla każdego splitu
def get_class_distribution(splits, classes):
    class_distribution = []
    for name, split in splits:
        total_split_size = split.shape[0]
        for target_class in classes:
            class_size = split.loc[split["target"] == target_class].shape[0]
            class_distribution.append({
                "df_name": name,
                "target_class": target_class,
                "size": class_size,
                "percentage_per_split": round((class_size / total_split_size) * 100, 4)
            })
    return class_distribution

class_distribution_df = pd.DataFrame(get_class_distribution(splits.items(), CLASSES))
class_distribution_df
```

Out[318…

	df_name	target_class	size	percentage_per_split
0	train	plus	1568	27.1140
1	train	minus	2194	37.9388
2	train	zero	971	16.7906
3	train	amb	1050	18.1567
4	valid	plus	209	28.9073
5	valid	minus	271	37.4827
6	valid	zero	127	17.5657
7	valid	amb	116	16.0443
8	test	plus	197	27.2853
9	test	minus	300	41.5512
10	test	zero	117	16.2050
11	test	amb	108	14.9584

In [436…

```python
def display_class_distribution(df, size, title):
    pivot = df.pivot(index="df_name", columns="target_class", values=size).fillna(0)

    data = pivot.values.astype(float)
    data_cum = data.cumsum(axis=1)

    _, ax = plt.subplots(figsize=(10, 5))

    for i, (colname, color) in enumerate(zip(pivot.columns, ['skyblue', 'tomato', 'chartreuse',  'blue'])):
        widths = data[:, i]
        starts = data_cum[:, i] - widths
        rects = ax.barh(pivot.index, widths, left=starts, height=0.5, label=colname, color=color)

        ax.bar_label(rects, label_type='center')

    ax.legend(ncols=len(pivot.columns), bbox_to_anchor=(0.68, 0.9), loc='lower left', fontsize='small')
    plt.title(title)
    plt.show()
```

In [437…

```python
# TODO: wykres rozkładu klas
display_class_distribution(class_distribution_df, "percentage_per_split", "Class distribution per split (%)")
```

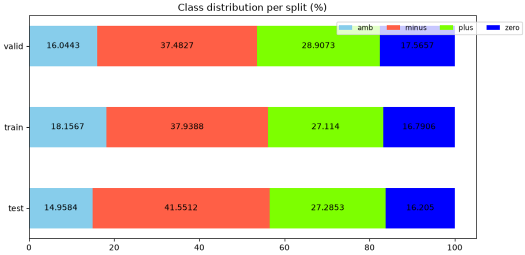

In [438…

```
display_class_distribution(class_distribution_df, "size", "Class distribution per split (count)")
```

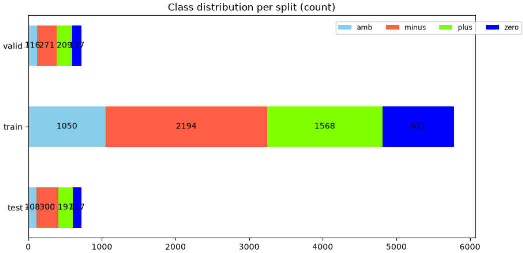

> 1. Nie, mamy tutaj klasy, które nie są zbalansowane, więc zastosowanie tylko i wyłącznie `accuracy` mogłoby spowodować, że przydzielanie każdej opinii do klasy `minus`. Przy takim rozkładzie klas lepiej zastosować inne metryki, np. f1-score.
> 2. Naiwny klasyfikator zawsze wybierający najczęstszą klasę (**minus**) osiągnąłby dokładność równą jej udziałowi w danym splicie: ok. 37,9% na zbiorze treningowym, ok. 37,5% na walidacyjnym oraz ok. 41,6% na testowym.
> 3. Tak, w każdym splicie rozkład klas jest zachowany proporcjonalnie i podobny.

Zadanie 3: Jak wygląda „typowy tekst”?

Długość tekstu jest jednym z pierwszych parametrów, które warto sprawdzić.

Dp wyświetlania tekstu proszę dodać cechy:

- `n_chars`: liczba znaków,
- `n_words`: liczba słów (regex `\w+`) oraz `n_words_split` (`split()` po białych znakach),
- `n_lines`: liczba linii.

Proszę policzyć co najmniej:

- minimum,
- medianę,
- średnią,
- 90. percentyl,
- 95. percentyl,
- 99. percentyl,
- maksimum.

Następnie proszę obejrzeć (i zanotować wnioski z obserwacji):

- 5 najkrótszych tekstów,
- 5 najdłuższych tekstów.

Pytania

- Czy ekstremalnie długi dokument zawsze jest błędem?
- Co długość dokumentów może później zmienić w tokenizacji, batchowaniu i chunkingu?
- Dlaczego `n_words_split` ≠ `n_words`? Co to mówi o przygotowaniu tekstów w tym zbiorze i jak może wpłynąć na tokenizatory w kolejnych labach?

In [440…

```
# TODO: do dodania n_chars, n_words, n_words_split, n_lines.
text_stats = {'n_chars': []}
text_stats['n_chars'] = all_df['text'].apply(len)
text_stats['n_words'] = all_df['text'].str.findall(r"\w+").str.len()
text_stats['n_words_split'] = all_df['text'].str.split().str.len()
text_stats['n_lines'] = all_df['text'].str.split('\n').str.len()

text_stats_summary = []

for key in text_stats.keys():
    text_stats_summary.append({
        'name': key,
        'min': np.min(text_stats[key]),
        'average': np.average(text_stats[key]),
        'p_90': np.percentile(text_stats[key], 90),
        'p_95': np.percentile(text_stats[key], 95),
        'p_99': np.percentile(text_stats[key], 99),
        'max': np.max(text_stats[key]),
    })
```

In [441…

```
# TODO: tabela statystyk długości
text_stats_summary_df = pd.DataFrame(text_stats_summary)
text_stats_summary_df
```

Out[441…

	name	min	average	p_90	p_95	p_99	max
0	n_chars	1	777.012313	1294.0	1605.65	2335.19	5391
1	n_words	1	114.322634	191.0	242.00	352.73	774
2	n_words_split	1	136.319175	228.0	288.65	414.73	987
3	n_lines	1	1.000000	1.0	1.00	1.00	1

In [442…

```
# TODO: histogram długości tekstów
import seaborn as sns
text_stats_summary_df = pd.DataFrame(text_stats)

sns.displot(data=text_stats_summary_df, x="n_chars", kde=True)
```

Out[442…

```
<seaborn.axisgrid.FacetGrid at 0x1d1943edf90>
```

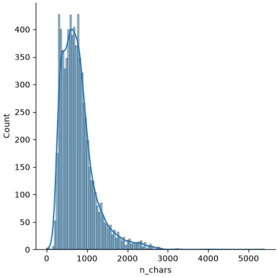

In [325…

```python
sorted_all = all_df['text'].sort_values(key=lambda x: x.str.len())
longest_5 = sorted_all[-5:]
shortest_5 = sorted_all[:5]

print("--- 5 SHORTEST ---")
for idx in shortest_5.index:
    text = all_df.loc[idx, 'text']
    print(f"Długość: {len(text)} | {text}")

print("\n-----------------------------------\n")

print("--- 5 LONGEST ---")
for idx in longest_5.index:
    text = all_df.loc[idx, 'text']
    print(f"Length: {len(text)} | {text}")
```

```
--- 5 SHORTEST ---
Długość: 1 | P
Długość: 29 | Marka Baccarat Hotels & Res o
Długość: 47 | Hotel , jak za tą kwotę ( 230 - 2 osoby & aut o
Długość: 51 | W grudniu czterogwiazdkowy Hotel Korona Spa & Wel l
Długość: 78 | Hotel powinien nazywać się MARNIOR ( z uwagi na kiepska jakosc uslug ) & Gwa r

-----------------------------------

--- 5 LONGEST ---
Length: 3917 | Ten Hotel to jest kpina z klienta . Hotel jedynie ładnie wygląda na zdjęciach i z daleka . Zdjęcia były robione dawno temu jak powstał ten hotel i nie aktualizowane do tej po
ry . Wystarczy tylko wejść do środka i czar pryska . Wszechobecny syf , obsługa w recepcji zachowująca się jakby nie wiedziała co tam robi , zimna woda i brak ogrzewania w pokojach to tylko
niektóre z rzeczy które mnie osłabiły . Obsługa w recepcji nie ma pojęcia gdzie są pokoje przez co od razu na początek zwiedzili śmy cały hotel w poszukiwaniu pokoju , który znajdował się n
a drugim końcu budynku . Korytarze są ciemne , tapeta odpadała ze ścian i wykładzina była ubrudzona jakby ktoś się na nią zrzygał lub zlał . W pokojach nie grzeją i panuje chłód . Wykładzin
a brudna i poplamiona . Nie działająca klimatyzacja , a po reklamacji w recepcji dostawali śmy informację , że będzie dopiero ciepło po 18 : 00 a w rzeczywistości przez cały pobyt nic nie g
rzało i było zimno w pokojach . Tapety w pokojach odpadały i były krzywo posklejane . Instalacja elektryczna na wierzchu , że strach cokolwiek dotknąć . Sprzęt stary , telewizor chyba 10 ca
lowy – kineskopowy , który odbierał może z 2 stacje na krzyż . Fotele wytarte , a w środku pod siedziskiem tylko grzyb i pleśń . Po podłączeniu lodówki do prądu zaczęła bardziej hałasować n
iż kosiarka spalinowa . Lodówka wydawała ogromny hałas i nic nie chłodziła … po poinformowaniu o tym fakcie Pana w recepcji otrzymali śmy informację , że trzeba było przy rezerwacji powiedz
ieć że się chce mieć lodówkę w pokoju . Bo jak nie to oni zamieniają działające z nie działającymi lodówkami do takich pokoi gdzie ktoś chciał żeby tam była … To są słowa recepcjonisty ! Ja
k to usłyszał em to nie wiedział em co powiedzieć . Na to wychodzi , że o wszystko trzeba prosić przy rezerwacji nawet o ciepłą wodę ? ! Żenada … Brak czajnika , szklanek i sztućców w pokoj
u co nie wspomnę , że to jest standard wyposażenia pokoi . Brak zamka w drzwiach od łazienki , Zimna woda w kranach przez co mycie się było nie możliwe . Jedyne źródło ciepła to grzejnik w
łazience na prąd , ale za dużo to nie dawało bo i tak cały czas była wilgoć . Wanna wykonana z słabej jakości plastiku co pod ciężarem nalanej wody trzeszczała i strzelała . Podłoga na balk
onach jakby była dopiero wylana , aż się zastanawiał em czy to jest jeszcze świeży beton … Okno balkonowe trzeba było umiejętnie otwierać bo jak nie to całe skrzydło wypadało . Nie mogę się
przyczepić do łóżek bo były bardzo wygodne i solidne . Prowizoryczne naprawy na szarą taśmę klejącą to jest to co już od progu rzuca się w oczy . Na kręgielni z 3 torów działają tylko 2 . Z
czego jeden który mieli śmy przyjemność mieć był wybrakowany . Po pierwsze nie było jednego kręgla , czyli nie dało się zbić wszystkich kręgli bo komputer twierdził że nadal tam stoi ten kt
órego nie ma i już . I mogli śmy być świadkami lewitujących kręgli zawieszonych z 5 cm nad ziemią przez maszynę . Stoły do bilarda były stare i zniszczone oraz miały ponadrywany materiał …
Na kilka zestawów do gry w bilard tylko jeden był kompletny i miał wszystkie bile . Stół do ping ponga zniszczony i z jednej strony jakby wygryziony . To był sprzęt którego lepiej nie dotyk
ać bo się rozpadnie . Stół od piłkarzyków był źle wypoziomowany przez co jednej osobie ciągle wlatywała piłka do bramki nawet jak nic nie robił ale za to druga osoba musiała się nieźle napo
cić żeby zdobyć punkt . Jazda windą przypominała jazdę jaką widzieli śmy w „ Szpitalu na perypetiach ” , no i ostatniego dnia winda odmówiła posłuszeństwa . Nie mogę się przyczepić do jedze
nia bo było dobre i dużo . Tylko obsługa nie wiem po co czekała aż zje się wszystko do ostatniego okruszka , zanim jak widzą , że coś się kończy to już iść po jedzenie żeby dołożyć na stół
szwedzki ? I podobna sytuacja była podczas ogniska z kiełbaskami . Musiało zabraknąć talerzyków , keczupu i musztardy żeby ktoś przyniósł i dołożył .
Length: 4023 | W hotelu gościmy regularnie od pięciu lat , magiczne miejsce nad klimatycznym jeziorem z dobra kuchnia oparta o lokalne produkty z masą ryb . Spory aquapark , hotel duży wiec
łatwo było o spokój , ciszę , odpoczynek . . . Rok temu bufety przeszły same siebie , przegrzebki , ślimaki , dziczyzna , kotlet z kangura , doskonały od kilku lat boeuf strogonow , duży wy
bór ryb , zarówno na ciepło jak i zimno . Te smaki zapamiętał em . Po wszystkim można było odpocząć w lobby barze z butelka piwa " świeże ” albo lampka wina . A do tego powtórzę ponownie sp
okój . . . Zachęcony czterokrotnie fantastycznie spędzonym urlopem dopełnionym całodziennym relaksem w saunach , grocie solnej i basenach aquaparku wybrał em sie do Gołębia po aż kolejny .
Rok 2017 urlop czas zacząć . Pierwsze wrażenie recepcja , w tym roku miłe zaskoczenie , ponieważ do hotelu przyjechali śmy grubo przed czasem , mimo to zaproponowano nam od razu pokój bez k
onieczności czekania na ustalona godzinę check in . Miło tym bardziej po podróży z drugiego końca Polski . Nawet proponowali śmy ze w sumie nie ma problemu i z chęcią pójdziemy na spacer po
Mikołajkach . . . plus dla obsługi hotelu . Poczuł em się fair , jak gość na którego sie czeka . Punkt dwa gorąco w pokoju , pół godziny kręcenia przy panelu i temp 28 stopni , ok kontakt z
recepcja - tytułem wyjaśnienia pani w recepcji sprostowała ze w pokojach nie ma klimatyzacji a " system " chłodzący wiec na pewno nie będzie tak chłodno jak przy klasycznym klimatyzatorze .
Ok ale skoro zgłaszam , przyśle konserwatora . Tu kolejny plus bo konserwator był już po 5 minutach , szybki przegląd i bingo - zapowietrzony system - po pięciu minutach było po problemie ,
chłodno , miło , przyjemnie . Pogratulować takiego pracownika - myśle na razie ok . Z tego miejsce serdeczne brawo dla pan pokojówek - sprzątanie szybkie , ręczniki wymieniane codziennie ,
pokój perfekcyjnie odkurzony , w sumie całość na plus . Ok jeśli dotrwali ście do tej pory pewnie pomyślicie co gość się czepia . . . to przejdźmy dalej . Bufety - jedzenie poprawne , śwież
e ale - na kolacje oprócz genialnych policzków wołowych i ślimaków z masłem czosnkowym coraz więcej smażonej kiełbasy , karkówki , a obok wspaniałych mazurskich ryb i teryny ( drobiowej lub
rybnej ) mielonka . . . aż bał em sie zapytać czy z puszki . Punkt drugi alkohole - rozmiar podawanych drinków nie satysfakcjonuje nawet krasnala - long island w tym rozmiarze to kpina a ce
na 50zl to kiepski żart . Piwo 12 zł - ok , ale wino zwietrzałe i ciepłe to duża wtopa . Kawa late znowu podawana w szklance na ok 200ml to kolejny minus . Dość długie oczekiwanie na realiz
acje zamówienia - przy obłożeniu ok 30 % w lobby barze - na lampkę wina trzeba czekać ponad 30 minut . No i teraz sedno dla którego tego hotelu nie wybiorę ponownie . Było cicho i spokojnie
, a tu nagle . . . Na balkonach głośno nawet po 22 : 00 i to grubo . Wystawione głośniki z muzyka ( króluje Zenon Martyniuk i podobne rytmy ) przynoszone z pobliskiego Orlenu piwo oraz bieg
ające z przeraźliwym wrzaskiem po korytarzach dzieci . W sumie to się im nie dziwie bo sam by m biegał gdyby moi rodzice imprezowali w pokoju . Dziwi tylko fakt czy w hotelu nie ma stosowny
ch do tego miejsc ? Np dyskoteka w podziemiach czy bar przy przystani . Dziwi fakt ze lepiej pic piwo z Orlenu w pokoju niż z hotelowego baru , terroryzując swoim chamskim i głośnym zachowa
niem resztę gości . Dzieci biegają , piwo się leje a w rytm disco polo co drugie słowo k . . . a ch . . . itp . Skąd te imprezy w pokojach przy własnym alkoholu , nie było tego . Czy do teg
o dążysz drogi Hotelu Gołębiewski ? Pytanie - zawsze mogł em zgłosić ze za głośno , ze impreza itp . . . tylko tu nie o to chodzi . Chodzi o to ze w trakcie tych kilku lat bardzo zmienił si
ę rodzaj klientów hotelu Gołębiewski . Coraz trudniej spotkać tu dżentelmena w garniturze , króluje natomiast przysłowiowy Janusz w skarpetach do sandałów . Przykre ale realne . Ja od Gołęb
```

```
ia muszę odpocząć , pierwszy raz z chęcią wracam do . . . domu
Length: 4107 | Właśnie wrócili śmy z " weekendowego " pobytu w Amaxie , skusili śmy sie akurat na ten hotel po przeczytaniu pozytywnych opinii . Wolna była willa 4 osobowa , wybrali śmy się
z mężem i dzieckiem - 2 doby to koszt 1600 zł więc tym bardziej jechali śmy ze spokojem , bez obaw co nas czeka na miejscu . Cena w końcu zobowiązuje ? Hotel położony w fajnym miejscu , aut
em mogli śmy zaparkować przy samym domku . Domek w środku wymagający remontu , taki typowy PRL , stare płytki , łazienka wymagająca remontu , stare meble , kominek , kuchnia wyposażona w ta
lerze sztucce itd . mała lodówka ( i tu po jej otwarciu bo przyjechalismy z miesem na girlla , wywalila sie szklana butelka od piwa - oczywiscie koszt dodatkowo platny ) . Domek 2 pietrowy
na dole salon z aneksem + lazienka wc . Na gorze 2 sypialnie w sypialniach pełno pająków , much , meszek - ale mąż jakoś sobie z nimi poradził - chociaż moim zdaniem obsługa hotelowa przed
przyjazdem gości powinna zadbać o coś takiego . Łazienki wyposazone w zestawy kosmetyków , nie wiem czy dobrej jakosci bo nie korzystalismy z niczego oprocz z mydla do mycia rak . To co nas
zdziwilo na samym wstepie to ilosc reczników - skoro domek jest na 4 osoby , to każda osoba powinna miec dla siebie komplet recznikow , tak zawsze dostawalismy w innych hotelach . O dziwo n
ie w Amaxie , 2 duże reczniki + 4 małe do wytarcia co najwyżej nóg lub włosów na głowie . Rozpalilismy grila posiedzielismy , poszlismy na spacer zwiedzic okolice , i to wszystko . O porank
u śniadanie , spodziewali śmy się wow - ze wzgledu na cene jaka zaplacilismy , jak i opinie obiektu . I tutaj kolejne zdziwienie - sniadania bardzo ubogie , na ciepło jajecznica , i parówki
, 3 / 4 rodzaje wedlin ser zolty twarog , jajka pomidory , ogorki , galaretki z jakim farszem w srodku , pasztet , pieczywo ( chleb i bulki ) platki sniadaniowe , z jogurtów tylko jogurt na
turalny augustowski , kawa herbata , sok z nalewaka , i lemoniada . Co nas zdziwilo najbardziej ? brak owocowów . Skusilismy sie na standard czyli jajecznice , pieczywo i wedline . Bylo sma
czne . Ale naparwde patrzac przez pryzmat ceny jaka oplacilismy za 2 noce to bardzo ubogo . W hotelu znajduje sie basen ( z tego co czytalam nawet 2 ) widzielismy jeden - na zewnątrz . Trco
hę owadów w nim pływało , więc wybralismy sie do centrum mikolajek , wypozyczylismy lodke i tak spedzilismy caly dzien . Wrocilismy ok godz 18 - domek nie sprzatniety - ale ok niedziela w k
oncu moze obsluga hotelowa ma wolne . Rozpalili śmy grilla , dzwonek do drzwi - obsluga sprzatajaca z pytaniem czy potrzebujemy sprzątniecia domku ? Stwierdzili śmy że o tej porze nie ma ju
ż sensu , na sprzątanie tym bardziej że z rana czeka nas wyjazd - więc jaki jest sens sprzatania o tej porze ? Myslalam ze pokoje sprzata sie rano ? Dodam ze butelki z woda rowniez nie zost
aly nam dostawione na kolejna dobe . W trakcie grillowania stwierdzilismy ze szkoda ze wybralismy ten hotel bo tylko zmarnowalismy pieniadze , a doplacajac 300 / 600 zł wiecej moglismy miec
pokoj w Hotelu Mikołajki , czy w Gołębiewskim . Ale tak to jest jak czlowiek chce czegos innego . Po grillu spakowalismy sie i o 20 wrocilismy do do domu , w koncu i tak nie mielismy nic do
stracenia - oprocz podrozy , kolejny nocleg i sniadanie bylo nie warte zachodu . Z + tylko i wyłącznie , grill ktory jest dostepny na miejscu , polozenie w spokojnym miejscu z fajnym widoki
em - a reszta to niestety minusy . Jestesmy wymagający z mezem - i cena po prostu nie jest adekwatna do jakosci . Zeby za pokoj zaplacic 200 zł za dobe to ok nie ma sie do czego czepiac , a
le za takie pieniadze jak my zaplacilismy oczekiwalismy wow . W każdym badz razie ostatni raz sugerowalismy sie opiniami ludzi w internecie , bo jak widac kazdy czlowiek ma inne wymagania ,
inne standardy itd . Moze dla niektorych pobyt w Amaxie to wymarzone wakacje , odpoczynek itd . Nie dla nas . My duzo jezdzimy , bylismy w wielu hotelach , i jestesmy osobami wymagajacymi .
Cena naszym zdaniem powinna isc w parze z jakoscia , tutaj tak sie nie stalo . Pierwsza wizyta w tym miejscu i ostatnia . Osobiscie nie polecamy .
Length: 4352 | Wykupiła m w państwa Hotelu pobyt świąteczny od dnia 23 . 12 - 26 . 12 . 2016r . dla 3 osób dorosłych i dwóch kotków . Rezerwacji dokonała m w miesiącu październiku 2016r . o
raz dokonała m przedpłaty w wysokości 50 % kosztów . Rezerwację potwierdziła m telefonicznie w dniu 19 . 12 . 2016r . Oferta którą Państwo przedstawili na portalu Hotelu na okres świąteczny
zachęcała do skorzystania z niej . Była tania , można było zabrać ze sobą zwierzęta piękna okolica . Jednak rzeczywistość okazała się zupełnie odmienna . Już w momencie przyjazdu spotkała m
nie niemiła sytuacja , tłum wrzeszczących ludzi przy recepcji domagających się przydziału pokoi . Ja też została m zakwalifikowana do tej grupy , ponieważ dla mnie też nie było pokoju . Obs
ługa recepcji totalnie nie była przygotowana do obsługi gości . Brak jakiekolwiek orientacji co do ilości wolnych pokoi oraz stanu ich wyposażenia , warunków bytowych . Rezygnacja ludzi z p
obytu w Hotelu na święta spowodowała , że udało się uzyskać pokój . Pokój był całkiem schludny w miarę posprzątany , ciepły , jedynie zdziwiły mnie muchy w kloszach , brudne klejące się z b
rudu firany i zasłony , brudne ściany , niedomyta łazienka zresztą i tak nieużyteczna , ponieważ nie było odpływu wody w kabinie prysznicowej i umywalce oraz brak ciepłej wody . Wszędzie ku
rz . Jakiś stary telewizor bez sprawnego pilota . Czyli koszmar . Przez dwa dniu mojego pobytu nikt z obsługi nie interesował się co się dzieje w pokoju ( może brak papieru toaletowego , wy
rzucenie śmieci ) . Kolacja w dniu przyjazdu była całkiem przyzwoita . Próbowała m wraz z rodziną skorzystać z atrakcji które oferowane były w ofercie świątecznej . Niestety : 1 . Szatnia p
rzy basenie śmierdziała moczem , strach się rozebrać , 2 . Basen brudna i zimna woda nie było widać dna na głębokości 1 , 2m , 3 . Drugi basenik czysty , ale zimna woda nie zachęcała do sko
rzystania z niego , 4 . Jakuzzi niekompletne ( służyło do codziennego mycia się gości bo była w nim ciepła woda ) , 5 . Kręgielnia - nieczynne wszystkie pasy ( nie wszyscy mogli z niej skor
zystać ) , 6 . Lodowisko nieczynne , nie było zamrożone na dzień przyjazdu gości , 7 . Brak informacji o atrakcjach w drugi dzień świąt ( zresztą i tak nie skorzystali śmy z nich ) , 8 . Br
ak możliwości korzystania z internetu – brak zasięgu WI - FI , Dzień wigilijny to koszmar . Brak informacji o godzinie kolacji jak i o zarezerwowanym stoliku . Koszmar zaczął się o 18 , 00
. Brak miejsc przy stole , kłótnie odświętnie ubranych gości , płacz głodnych dzieci , w Hotelu nie funkcjonowała restauracja w dniu wigilii . Następne rozczarowanie to brak pełnej zastawy
kolacyjnej . Jakieś tam talerzyki i sztućce , brak bulionówek na zupy szkła do napoi , zresztą nie były potrzebne bo ani barszczu ani kompotu ani nawet wody nie dostali śmy . Potrawy wigili
jne na naszym stole to ryba w galarecie , sałatka jarzynowa , śledź w śmietanie . Wymienione potrawy były podane w skąpych miseczkach byle jaki . Zdobycie pierogów to już horror . Serwowane
dania wigilijne było poniżej krytyki . Puste pierogi marnej jakości . Zresztą jak i reszta potraw . Hitem wigilii było podanie na koniec wieczerzy półmiski z gotowanymi ziemniakami ( tylko
do czego ) . Obsługa - ludzie młodzi mimo chęci do pracy nie potrafiła zorganizować prawidłowej „ wydawki „ potraw . Sami byli zagubieni w powstałej sytuacji . Brak osoby odpowiedzialnej za
obsługę na Sali . Głodni ludzie sami chodzili do kuchni Hotelu celem zdobyć „ czegoś ” do jedzenia . Widok tego co się działo na sali , rozwścieczeni , zdezorientowani ludzie , płaczące dzi
eci zmusił nas do podjęcia decyzji o opuszczeniu Hotelu w dniu następnym . Brak zainteresowania na recepcji kto opuszcza Hotel i dlaczego . Nie było z kim rozmawiać na temat reklamacji oraz
dopłaty do rezerwacji ( nie dopłaciła m za pobyt ) . Nie wiem czy była m zameldowana w Państwa Hotelu . Jest to karygodne aby w tych czasach tak traktować ludzi . W związku z brakiem jakich
kolwiek przeprosin z Państwa strony za zaistniałą sytuację , która długo pozostanie w pamięci mojej rodziny , zepsucie świątecznego nastroju i samych Świat Bożego Narodzenia oraz upokorzeni
e i arogancja wobec mojej rodziny proszę o zwrot poniesionych kosztów związanych z opłaceniem pobytu oraz koszty transportu . Proszę omijać ten Hotel szerokim łukiem ! ! ! ! ! ! ! ! ! ! ! !
! ! ! ! ! ! ! !
Length: 5391 | Wybór sylwestrowego pakietu w tym hotelu za gigantyczne pieniądze ( jak na zaproponowane warunki i " atrakcje " ) to jeden z naszych największych błędów . Kierowali śmy się r
eklamami , ogłoszeniami i wizerunkiem hotelu , który kreuje się na mega luksusowy . . . Po 4 godzinach podróży z dzieckiem i kotem otrzymali śmy kartę do pokoju hotelowego . . . Kiedy do ni
ego weszli śmy z wrażenia opadła m na łóżko , zaścielone pomiętą , wygniecioną pościelą . W pokoju . . . brud . Wykładzina poplamiona , w pokoju jedno okno , balkonowe , nieszczelne , probl
em z otwarciem ( jak wywietrzyć pokój , z jednym balkonowym oknem , którego nie można uchylić , kiedy przyjeżdża się z kotem ? ) na szybach skraplająca się woda , firanki pogniecione , poza
ciągane , niedoprane . Stolik nocny z zepsutą szufladą . Abażury lampek mocno po przejściach , ściany obrzydliwie brudne , zaplamione , brak klimatyzacji . No i wisienka na torcie - łazienk
a . Oj . . . na grzejniku służącym do suszenia ręczników gruba warstwa kurzu , prysznic . . . . z zasilikonowanym grzybem . Myślę , że żaden cukiernik nie powstydził by się takich umiejętno
ści zdobienia tortów jakie posiada osoba , która silikonowała prysznic na kilka godzin przed naszym przyjściem ( charakterystyczny zapach ) , bateria łazienkowa kwalifikująca się jedynie do
wymiany . Oświetlenie w łazience tragiczne , zrobienie makijażu w takim świetle , tylko przy doświetlaniu latarką z telefonu . Tyle o pokoju - pani " kierownik " czy też " menadżer " nawet
nie broniła się , bo i jak ? Skoro miała ten brud przed własnymi oczyma ? Zmieniono nam pokój . Czekali śmy na niego prawie 2 godziny . W tym czasie nikt nie zaproponował nam zejścia do res
tauracji na kawę , poszli śmy sami . . . Kolejny pokój sprzątany na szybko , nieco czystszy , ale ilość odświeżacza powietrza wywoływała odruch wymiotny . . . Po jakimś czasie okazało się ,
że termostat przy kaloryferze w pokoju nie działa i kaloryfer na 25m2 grzał całą parą . . . Klimatyzacji również brak . Nie wiem , jak ludzie wytrzymują tam latem , my musieli śmy zamykać k
ota w transporterze średnio co 2 godziny , żeby otworzyć okno na oścież i wychładzać pokój . W nocy było strasznie . Generalnie pokoje małe , niewygodne , nieergonomicznie urządzone . Jedze
nie bardzo słabe . Surówki " z wiadra " , typowa niedorobiona garkuchnia . . . Menu sylwestrowe wołające o pomstę do nieba . Jeśli ktoś skusił się na szumnie nazwane BBQ ribbs , to chyba po
łamał na nich zęby . Rozreklamowany " spacer " po czerwonym dywanie w błysku fleszy nijak miał się do rzeczywistości , zabrakło fleszy . . . Orkiestra grająca na zabawie sylwestrowej przygo
towała dziwny repertuar , a kiedy w przerwie grał didżej i było już grubo po północy ludzie zaczęli się dobrze bawić , znowu weszła orkiestra . Ludzie prosili , żeby już nie grała , żeby zo
stał didżej , powiedziano im , że orkiestra musi grać . . . dopiero po interwencji kilku osób w recepcji udało się pozbyć orkiestry . Open bar proponował pięć drinków , a po godzinie 2 w no
cy zaczęto ludziom odmawiać ich przygotowywania . Kelnerzy serwowali niewybredne żarty poproszeni o doniesienie wódki na stół . . . Na stołach brakowało napojów gazowanych , trzeba było o n
ie prosić , a kelnerzy niechętnie je donosili . Zorganizowano zabawę sylwestrową dla dzieci , ale panie animatorki nie panowały nad grupą - dzieci wychodziły z sali gdzie i kiedy chciały ,
a przecież hotel znajduje się nad jeziorem . . . Obsługa hotelu . . . nikt nic nie wie , wszyscy niedoinformowani . Nikt nie powiedział nam , ze wejściówki do zoo i fokarium są w pokoju , ż
e jeśli chcemy iść to musimy je zabrać , a kiedy przed wyjściem pytali śmy o to w recepcji , powiedziano nam , że wystarczy przy wejściu do zoo powiedzieć , że jesteśmy w hotelu . W kasie z
oo jednak nikt nic o tym nie wiedział . . . ehhh . Do tego kelnerzy . . . miała m wrażenie , że przez 3 doby pobytu , od śniadania do godziny 22 , a potem w sylwestra do późnej nocy obsługi
wali nas ci sami ludzie . Po rozmowach z gośćmi wiemy , że nie tylko my czuli śmy się niezręcznie przez to , że obsługują nas po prostu zmęczeni pracownicy . Po samym sylwestrze okazało się
, że mimo , że informowali śmy , że przyjeżdżamy z kotem , pierwszy zaproponowany nam pokój znajdował się dokładnie od strony , przy której puszczano fajerwerki . . . Bilard w barze ( jeden
stół ) płatny . Kręgle płatne ( dwa tory , cena wysoka , kule poobijane , niesprawna maszyna podnosząca kręgle , która stawiała z powrotem nawet te , które zostały zbite ) . Basen z bardzo
mocno chlorowaną wodą , na 90 pokojów hotelowych , domków na drzewach i rybaczówce basen zdecydowanie zbyt mały . Jedno jacuzzi . . . wiecznie okupowane . łącznie pobyt na 3 noce z balem sy
lwestrowym wyniósł nas około 3500zł . . . W tej cenie spodziewała m się chociażby . . . czystości ? I dobrego jedzenia . Zawiodła m się bardzo , więcej tam nie pojadę . Gdyby nie to , że by
li śmy ze zmęczonym podróżą dzieckiem i kotem , wyjechali by śmy gdy tylko zobaczyli śmy pokój . Sytuację uratowało ciekawe zoo i fokarium , które były atrakcją dla dziecka . Nie polecam ,
znam znacznie ciekawsze miejsca , a tu mam wrażenie , że po prostu nas naciągnięto . Pomijam , że nawet nie usłyszeli śmy zwykłego " przepraszam " za sytuację z pokojem . Na dowód , zamiesz
czam zdjęcia , a wy sami sobie odpowiedzcie , czy te 3 noce w takich warunkach warte były tych pieniędzy . . .
```

> 1. Oczywście, że nie. Najczęściej, co widać powyżej długa opinia świadczy o niezadowoleniu klienta z danej usługi.
> 2. Wpływ długości opini na tokenizację, batchowanie i chunking?
>   - 2.1. **Tokenizacja:** Zbyt długie opinie mogłyby przekroczyć maksymalne ograniczenie kontekstu modelu.
>   - 2.2. **Batchowanie:** Ekstremalnie długie sekwencje drastycznie zwiększają zużycie pamięci (VRAM) podczas przetwarzania batcha.
>   - 2.3. **Chunking:** Decydujemy, czy dzielić dokument na mniejsze fragmenty, czy odrzucać nadmiar tekstu, co może rzutować na utratę kontekstu wypowiedzi i pogorszenie jakości odpowiedzi.
> 3. Różnica wynika z metody liczenia: `n_words_split` dzieli tekst po prostu po spacjach, przez co traktuje słowa wraz z interpunkcją jako jedną całość. Z kolei `n_words` używa wyrażenia regularnego, które pomija znaki interpunkcyjne. Pokazuje to, że teksty nie przeszły jeszcze dokładnego, wstępnego oczyszczania. W kolejnych labach może to sprawić, że tokenizator wygenerują zbyt wiele nietypowych tokenów przez znaki specjalne, co może obniżyć jakoś modelu.

Zadanie 4: Szum danych

Tekst naturalny nie jest sterylny.

Proszę sprawdzić, ile rekordów zawiera co najmniej jeden z poniższych elementów:

- URL,
- adres e-mail,
- sekwencję wielu wykrzykników lub znaków zapytania,
- dużo WIELKICH LITER,
- znaki nowej linii,
- tekst krótszy niż 20 znaków.

Proszę nie usuwać ich automatycznie!

> Najpierw wykrywamy zjawisko. Potem decydujemy, czy jest błędem, sygnałem czy częścią danych.

Proszę też sprawdzić, czy którakolwiek flaga szumu jest skorelowana z etykietą. Czy to sygnał, artefakt, czy shortcut?

In [326...

```
# TODO: proszę obliczyć poniższe flagi bool
#
# has_url, has_email, has_punct_burst, has_newline, is_very_short, high_uppercase
#
# Proponowany próg high_uppercase: uppercase_ratio > 0.5,
# zaleca się eksperyment z tym progiem.
#
```

```python
# UWAGA: w tym zbiorze interpunkcja jest oddzielona spacjami (np. "! ! !"),
# więc prosty wzorzec [!?]{2,} jej nie wykryje.

url_regex = r'https?://\S+|www\.\S+'
email_regex = r'\S+@\S+\.\S+'
punct_burst_regex = r'[!?]\s*[!?]'
uppercase_regex = r'[A-ZĄĆĘŁŃÓŚŹŻ]'

has_url = all_df['text'].str.contains(url_regex, na=False)
has_email = all_df['text'].str.contains(email_regex, na=False)
has_punct_burst = all_df['text'].str.contains(punct_burst_regex, na=False)
has_newline = all_df['text'].str.contains('\n')
is_very_short = (all_df['text'].str.len() < 20)
uppercase_letters = (all_df['text'].str.findall(uppercase_regex).str.len() / all_df['text'].str.len() > 0.5)

print(f'Has url sum: {has_url.sum()}')
print(f'Has email sum: {has_email.sum()}')
print(f'Has punct burtst sum: {has_punct_burst.sum()}')
print(f'Is veruy short rows: {is_very_short.sum()}')
print(f'Has new line sum: {has_newline.sum()}')
print(f'Uppercase letters rows: {uppercase_letters.sum()}')
```

```
Has url sum: 9
Has email sum: 0
Has punct burtst sum: 808
Is veruy short rows: 1
Has new line sum: 0
Uppercase letters rows: 10
```

Zadanie 5: Duplikaty

Duplikat w danych treningowych nie zawsze jest problemem. Jednak duplikat między zbiorami train i test może zafałszować wyniki.

Zaczniemy od dwóch wersji tekstu:

1. `text_raw` : oryginał,
2. `text_norm` : wersja używana wyłącznie do oceny duplikatów.

Normalizacja:

- Unicode NFKC,
- lowercase,
- redukcja białych znaków,
- trim.

> Nie usuwamy interpunkcji i nie robimy agresywnego preprocessingu.

In [327…

```python
# TODO:
# preprocessing

# TODO:
# 1. jakie dokładne duplikaty text_raw,
# 2. jakie duplikaty text_norm,
# 3. 10 przykładowych grup duplikatów,
# 4. czy ten sam text_norm występuje w więcej niż jednym splicie?

# MIEJSCE NA KOD


def normalize_text(text):
    text = unicodedata.normalize('NFKC', text).lower()
    return re.sub(r'\s+', ' ', text).strip()

all_df['text_raw'] = all_df['text']
all_df['text_norm'] = all_df['text'].apply(normalize_text)

for split_name in ['train', 'valid', 'test']:
    split_subset = all_df[all_df['split'] == split_name]
    raw_dups = split_subset['text_raw'].duplicated().sum()
    norm_dups = split_subset['text_norm'].duplicated().sum()
    print(f"[{split_name.upper()}] Inner split -> raw: {raw_dups}, norm: {norm_dups}")

print("-" * 50)

print("Examples of duplicate groups (text_norm):")
dup_groups = (
    all_df.groupby('text_norm')
    .filter(lambda x: len(x) > 1)
    .groupby('text_norm')
    .agg(
        count=('text', 'count'),
        splits=('split', lambda x: sorted(x.unique().tolist()))
    )
    .sort_values('count', ascending=False)
    .head(10)
)
print(dup_groups)
```

```
[TRAIN] Inner split -> raw: 0, norm: 0
[VALID] Inner split -> raw: 0, norm: 0
[TEST] Inner split -> raw: 0, norm: 0
--------------------------------------------------
Examples of duplicate groups (text_norm):
Empty DataFrame
Columns: [count, splits]
Index: []
```

Funkcja `audit_split_leakage`

Proszę napisać funkcję:

`audit_split_leakage(df, text_col="text_norm", split_col="split")`
która zwróci rekordy występujące w więcej niż jednym splicie.

W wyniku chcemy co najmniej:

- tekst / fingerprint,
- liczbę wystąpień,
- listę splitów,
- etykiety.

To będzie pierwszy element naszej semestralnej biblioteki ewaluacyjnej.

In [328…

```python
def audit_split_leakage(df, text_col="text_norm", split_col="split", label_col = "target"):
    leakage_mask =  df.groupby(text_col)[split_col].transform('nunique') > 1

    return (
        df[leakage_mask].groupby(text_col)
        .agg(
            count = (split_col, 'count'),
            splits = (split_col, lambda x: sorted(x.unique().tolist())),
            lables = (label_col, lambda x: sorted(x.unique().tolist()))
        )
        .sort_values('count', ascending = False)
    )

print(audit_split_leakage(all_df))
```

```
Empty DataFrame
Columns: [count, splits, lables]
Index: []
```

> Jak widzimy, żadna opinia nie jest powielona ani wewnątrz splitu, ani pomiędzy nimi.

Zadanie 6: Prawie duplikaty

Exact match nie wystarczy.

Przykład:

- `Świetny hotel. Polecam!`
- `Świetny hotel - polecam!!!`

Dla człowieka to prawie ten sam tekst. Hash ich nie połączy.

Na próbce danych proszę zbudować prosty detektor zdań, które są prawie duplikatami:

1. `TfidfVectorizer(analyzer="char_wb", ngram_range=(3, 5))`,
2. `NearestNeighbors(metric="cosine")`,
3. dla każdego tekstu proszę znaleźć najbliższego **innego** sąsiada (uwaga: przy `n_neighbors=1` sąsiadem jest zwykle ten sam dokument, więc pobierz kilku i pomiń siebie),
4. proszę policzyć podobieństwo jako `1 - cosine_distance`,
5. proszę policzyć pary z podobieństwem np. `>= 0.90`, osobno w obrębie jednego splitu i między splitami.

Nie chodzi o idealny deduplikator

Celem jest zobaczenie, że decyzja "duplikat / nie duplikat" sama może być problemem modelowym.

In [329…

```python
# TODO nearest_other_neighbour
N_NEIGHBORS = 2
SIMILARITY_THRESHOLD = 0.90

vectorizer = TfidfVectorizer(analyzer="char_wb", ngram_range=(3, 5))

X = vectorizer.fit_transform(all_df['text_norm'])

def nearest_other_neighbor(X):
    knn = NearestNeighbors(metric="cosine")
    knn.fit(X)

    distances, indices = knn.kneighbors(X, n_neighbors=N_NEIGHBORS)
    j = indices[ :, 1]
    sim = 1 - distances[: , 1]
    return j, sim


# MIEJSCE NA KOD
j, sim = nearest_other_neighbor(X)
```

In [380…

```python
def find_pairs(df, j, sim, threshold_min = SIMILARITY_THRESHOLD, threshold_max = 100):
    pairs = pd.DataFrame({
        "i": range(len(df)),
        "j": j,
        "sim": sim
    })

    pairs = pairs[(pairs["sim"] >=  threshold_min) & (pairs["sim"] <= threshold_max)]
    pairs = pairs[pairs["i"] < pairs["j"]]

    pairs["cross_split"] = df["split"].values[pairs["i"]] != df["split"].values[pairs["j"]]
    pairs["i_text"] = df["text"].values[pairs["i"]]
    pairs["j_text"] = df["text"].values[pairs["j"]]

    return pairs
```

In [331…

```python
pairs = find_pairs(all_df, j, sim)
pairs
```

Out[331…

	i	j	sim	cross_split	i_text	j_text
1344	1344	6642	0.999948	True	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i H...	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i H...
3413	3413	5612	0.962757	False	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejedneg...	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejedneg...
3572	3572	4360	0.943419	False	Wracając jednak do grupy hoteli dysponujących więcej niż tysiącem pokoi , na 9 pozycji znalazły się hotele należące do Wojskowej Agencji Mieszkaniowej . Gru...	Grupa , która przez chwilę promowała się pod mało rozwojową nazwą Hotele 21 (miało być 21 obiektów , a nawet – wliczając np . niezrealizowany projekt hotel...

> Niestety widzimy tutaj, że mamy 3 opinie, które są bardzo podobne do innych. Dodatkowo jedna para z tych podobieństw występuje pomiędzy splitami.

Zadanie 7: Czy split jest częścią danych?

Proszę porównać:

A. oficjalny split

`train / validation / test`

B. naiwny random split

po połączeniu wszystkich rekordów:

`train_test_split(..., stratify=target, random_state=42)`
Nie trenujemy jeszcze modelu docelowego. Chcemy zobaczyć, czy sam sposób dzielenia danych może zmienić eksperyment.

Proszę sprawdzić dla obu wariantów:

- rozkład klas,
- exact duplicates między train/test,
- near-duplicates, jeśli masz czas.

Pytanie

Czy losowy split jest zawsze metodologicznie poprawny?

Proszę pomyśleć o:

- użytkownikach,
- autorach,
- czasie,
- źródłach,
- dokumentach należących do tej samej sprawy,
- wielu fragmentach pochodzących z jednego dokumentu.

In [332…

```
# MIEJSCE NA KOD
from sklearn.model_selection import train_test_split

X_train_rnd, X_test_rnd = train_test_split(all_df, test_size=0.2, stratify=all_df["target"])
X_test_rnd, X_val_rnd = train_test_split(X_test_rnd, test_size=0.5, stratify=X_test_rnd["target"])

X_train_rnd["split"] = "train"
X_val_rnd["split"] = "val"
X_test_rnd["split"] = "test"

all_rnd_df = pd.concat([X_train_rnd, X_val_rnd, X_test_rnd], ignore_index=True)

print(f"Train: {X_train_rnd.shape}, test: {X_test_rnd.shape}, val: {X_val_rnd.shape}")
```

```
Train: (5782, 5), test: (723, 5), val: (723, 5)
```

In [333…

```
# MIEJSCE NA KOD
splits_rnd =  zip(["train", "test", "val"], [X_train_rnd, X_test_rnd, X_val_rnd])
class_distribution_rnd_df = pd.DataFrame(get_class_distribution(splits_rnd, CLASSES))
class_distribution_rnd_df
```

Out[333…

	df_name	target_class	size	percentage_per_split
0	train	plus	1579	27.3089
1	train	minus	2212	38.2567
2	train	zero	972	16.8108
3	train	amb	1019	17.6237
4	test	plus	197	27.2476
5	test	minus	276	38.1743
6	test	zero	122	16.8741
7	test	amb	128	17.7040
8	val	plus	198	27.3859
9	val	minus	277	38.3126
10	val	zero	121	16.7358
11	val	amb	127	17.5657

In [439…

```
display_class_distribution(class_distribution_rnd_df, "percentage_per_split", "Class distribution per split (%)")
display_class_distribution(class_distribution_rnd_df, "size", "Class distribution per split (count)")
```

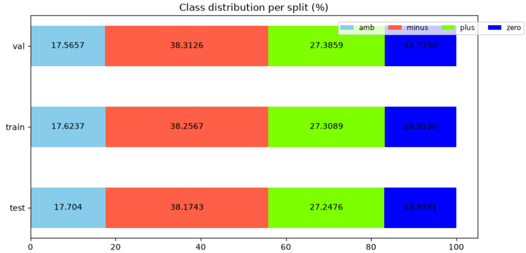

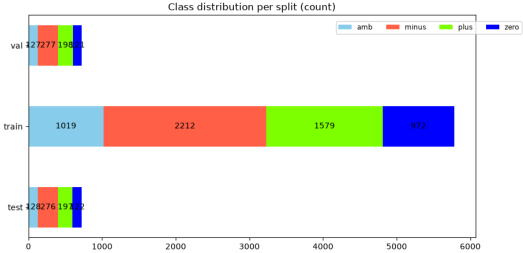

> Q: Czy losowy split jest zawsze metodologicznie poprawny? A: Oczywiście, że nie. Istnieje wiele czynników strukturalnych, przez które losowy podział prowadzi do wycieku danych (data leakage) i optymistycznie zafałszowanych wyników. Przykłady takich problemów to:
>
> - **Użytkownicy i Autorzy:** Jeśli w zbiorze mamy wiele wpisów od tych samych osób, losowy split rozdzieli je pomiędzy trening a test. Model nie uczy się wtedy ogólnego wzorca, tylko „zapamiętuje" specyficzny styl pisania użytkownika.
> - **Czas (Time-based splitting):** W danych uporządkowanych w czasie losowy podział powoduje tzw. wyciek z przyszłości (model uczy się na danych późniejszych, aby przewidywać wcześniejsze, co w rzeczywistości jest niemożliwe).
> - **Źródła i Dokumenty powiązane:** Dokumenty pochodzące z tego samego źródła czy tej samej książki są silnie skorelowane. Losowanie sprawia, że niemal identyczne fragmenty trafiają do obu zbiorów, drastycznie fałszując metryki ewaluacji.

In [335…

```
test_train_norm_duplicated_rnd = set(X_train_rnd["text_norm"]).intersection(set(X_test_rnd["text_norm"]))
test_train_norm_duplicated_rnd
```

Out[335…

```
set()
```

In [336…

```
# MIEJSCE NA KOD
vectorizer_rnd = TfidfVectorizer(analyzer="char_wb", ngram_range=(3, 5))
X_rnd = vectorizer_rnd.fit_transform(all_rnd_df['text_norm'])

j_rnd, sim_rnd = nearest_other_neighbor(X_rnd)
pairs_rnd = find_pairs(all_rnd_df, j_rnd, sim_rnd)
pairs_rnd
```

Out[336…

	i	j	sim	cross_split	i_text	j_text
1174	1174	3195	0.962757	False	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejedneg...	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejedneg...
3828	3828	5603	0.943419	False	Grupa , która przez chwilę promowała się pod mało rozwojową nazwą Hotele 21 (miało być 21 obiektów , a nawet – wliczając np . niezrealizowany projekt hotel...	Wracając jednak do grupy hoteli dysponujących więcej niż tysiącem pokoi , na 9 pozycji znalazły się hotele należące do Wojskowej Agencji Mieszkaniowej . Gru...
4051	4051	6179	0.999948	True	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i H...	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i H...

> Podobnie jak na danych oryginalnie podzielonych, brak tutaj bezpośrednich duplikatów. Jednak ponownie widzimy 3 pary opinii do siebie bardzo zbliżonych i tak samo jedna z tych par to podobieństwo między różnymi splitami.

Zadanie 8: Eksperyment: wyciek danych potrafi „ulepszyć" model

Teraz użyjemy bardzo prostego klasyfikatora wyłącznie jako sondy diagnostycznej. Nie optymalizujemy hiperparametrów. To będzie temat kolejnego laboratorium.

Pipeline:

`TF-IDF → Logistic Regression`

Najpierw policzymy wynik na poprawnym splicie, a potem celowo zanieczyścimy train przykładami z testu.

Hipoteza

Proszę sformułować przed uruchomieniem założenie:

> Jak zmieni się accuracy / macro-F1 po wprowadzeniu leakage i dlaczego?

> Obie metryki będą rosły wraz ze wzrostem wycieku. Dzieje się tak, ponieważ model zobaczy dane dwukrotnie: raz w treningu i raz w predykcji, co sztucznie poprawi ich jakość.

In [337…

```
probe = Pipeline([
    ("tfidf", TfidfVectorizer(
        ngram_range=(1, 2),
        min_df=2,
        max_features=50_000,
        sublinear_tf=True,
    )),
    ("clf", LogisticRegression(
        max_iter=1000,
        random_state=RANDOM_STATE,
    )),
])

def evaluate_probe(train_part: pd.DataFrame, test_part: pd.DataFrame):
    probe.fit(train_part["text"], train_part["target"])
    pred = probe.predict(test_part["text"])
    return {
        "accuracy": accuracy_score(test_part["target"], pred),
        "macro_f1": f1_score(test_part["target"], pred, average="macro"),
    }

# Wynik bazowy na oficjalnym splicie:
clean_score = evaluate_probe(train_df, test_df)
clean_score
```

Out[337…

```
{'accuracy': 0.8365650969529086, 'macro_f1': 0.7965659940906175}
```

In [338…

```python
# CELowo tworzymy błędny eksperyment: dokładamy część TESTU do TRAIN.
# Proszę nie robić tego nigdy w prawdziwej ewaluacji!!! :)

def score(model, part):
    pred = model.predict(part["text"])
    return accuracy_score(part["target"], pred), f1_score(part["target"], pred, average="macro")

rows = []
for frac in [0.0, 0.05, 0.10, 0.20, 0.50, 1.0]:
    leaked = test_df.sample(frac=frac, random_state=RANDOM_STATE)
    train_leaky = pd.concat([train_df, leaked], ignore_index=True)
    probe.fit(train_leaky["text"], train_leaky["target"])
    m = test_df.index.isin(leaked.index)
    row = {"leak_fraction": frac}
    row["acc_all"], row["f1_all"] = score(probe, test_df)
    row["acc_leaked"], row["f1_leaked"] = score(probe, test_df[m]) if m.any() else (np.nan, np.nan)
    row["acc_unleaked"], row["f1_unleaked"] = score(probe, test_df[~m]) if (~m).any() else (np.nan, np.nan)
    rows.append(row)

pd.DataFrame(rows)
```

Out[338…

	leak_fraction	acc_all	f1_all	acc_leaked	f1_leaked	acc_unleaked	f1_unleaked
0	0.00	0.836565	0.796566	NaN	NaN	0.836565	0.796566
1	0.05	0.837950	0.793777	0.916667	0.824472	0.833819	0.791962
2	0.10	0.839335	0.794763	0.944444	0.903195	0.827692	0.784910
3	0.20	0.855956	0.820547	0.951389	0.934320	0.832180	0.792879
4	0.50	0.889197	0.867642	0.955679	0.945997	0.822715	0.791268
5	1.00	0.958449	0.951080	0.958449	0.951080	NaN	NaN

Analiza

Proszę odpowiedzieć krótko:

1. Jak duża była różnica dla każdej wartości leak_fraction?
2. Czy wynik wzrósł tak mocno, jak było oczekiwane?
3. Dlaczego wyciek przez duplikaty może być bardziej lub mniej szkodliwy zależnie od modelu?
4. Czy wysoki wynik sam w sobie pozwala odróżnić dobry model od błędnej ewaluacji?
5. Jakie testy automatyczne dobrze dodać do pipeline'u danych?
6. Czy wzrost wyniku wynika z zapamiętania wyciekłych rekordów (acc_leaked), czy z poprawy na pozostałych (acc_unleaked)?

> 1. Tak jak oczekiwano, wraz ze wzrostem liczby wycieków (`leak_fraction`), systematycznie zwiększała się ogólna dokładność modelu oraz F1-score.
> 2. Tak, wzrost był w pełni zgodny z przewidywaniami i skalował się wraz ze zwiększaniem udziału wyciekłych danych w zbiorze.
> 3. Zdecydowanie – zależy to od specyfiki i podatności modelu na zapamiętywanie. Przykładowo, proste modele drzewiaste bez problemu zapamiętają dokładne powtórzenia i dopasują się do nich, osiągając sztucznie zbyt dobrą dokładność. Z kolei modele o silniejszej regularizacji lub prostsze modele liniowe mogą inaczej reagować, choć i tak wyniki ulegną wypaczeniu.
> 4. Nie, istnieje wiele czynników mogących wpłynąć na wysoki wynik. Jednak podejrzanie wysoki lub idealny wynik zawsze powinien zmuszać do refleksji i głębszej weryfikacji.
> 5. Można celowo zanieczyścić dane i porównać wynik dla nich z wynikami naszego modelu, jesli nasze wyniki będą podobe bądź lepsze to może oznaczać wyciek.
> 6. Warto wdrożyć automatyczne testy sprawdzające rozłączność zbiorów (np. zweryfikowanie, że zbiory treningowe, walidacyjne i testowe mają zerową część wspólną pod kątem unikalnych tekstów, używając np. podobieństwa cosinusowego), aby zapobiec wyciekom przed rozpoczęciem treningu.
> 7. Wzrost ogólnego wyniku wynikał stricte z zapamiętania wyciekłych rekordów. Dla przykładu: przy `leak_fraction=0.10` `acc_all` wynosiło ok. 0.85, a przy `leak_fraction=0.50` wzrosło do ok. 0.90. Jednocześnie metryki liczone wyłącznie dla danych czystych (`acc_unleaked`) pozostały na niezmienionym poziomie, po prostu zwiększył się udział zanieczyszczonych danych w całym zbiorze, a ich wyższa dokładność zdominowała średnią wynikową.

Zadanie 9: Dane do kolejnego laboratorium

Na następnych zajęciach będziemy budować baseline'y klasyfikacyjne. Proszę zatem przygotować czysty, wersjonowany artefakt.

Minimalna polityka czyszczenia

Rekomendujemy:

- usunąć rekordy bez tekstu lub labelu,
- **nie modyfikować** `validation` i `test` (zachować oficjalne rozmiary); duplikaty w tych splitach tylko oznaczyć flagą,
- z `train` usunąć exact duplicates wewnątrz `train` oraz rekordy, których `text_norm` występuje w `validation` lub `test` ,
- nie zmieniać treści tekstu bez uzasadnienia,
- nie usuwać "dziwnych" tekstów tylko dlatego, że wyglądają dziwnie,
- każdą operację zapisać w manifeście wraz z liczbą usuniętych rekordów.

Do zapisania

```
artifacts/
├── polemo2_clean.parquet
└── splits.json
```

`splits.json` powinien zawierać co najmniej:

- `random_state` ,
- liczebności splitów,
- listę klas,
- datę / wersję źródła lub URL,
- opis wykonanych operacji czyszczenia,
- `label_map` ,
- liczebności splitów przed i po czyszczeniu,
- SHA-256 pliku `polemo2_clean.parquet` ,
- wersje Pythona, pandas i scikit-learn.

In [339…

```python
print("Data frame shape before cleaning:")
all_df.groupby("split").size().rename("rows_before_cleaning").to_frame()
```

```
Data frame shape before cleaning:
```

Out[339…

	rows_before_cleaning
split	
test	722
train	5783
valid	723

In [340…

```python
# TODO: zdefiniować clean_df zgodnie z polityką czyszczenia

clean_df = all_df.copy()
cleaning_log = []

missing_text = clean_df["text"].isna() | clean_df["text"].astype("string").str.strip().eq("")
missing_target = clean_df["target"].isna()
invalid_rows = missing_text | missing_target
cleaning_log.append({"op": "drop_missing_text_or_target", "removed": int(invalid_rows.sum())})
clean_df = clean_df.loc[~invalid_rows].copy()

train_mask = clean_df["split"].eq("train")
train_duplicates = train_mask & clean_df.duplicated(subset=["text"], keep="first")
cleaning_log.append({"op": "drop_exact_duplicates_from_train", "removed": int(train_duplicates.sum())})
clean_df = clean_df.loc[~train_duplicates].copy()

other_split_texts = set(clean_df.loc[clean_df["split"] != "train", "text_norm"])
cross_split_duplicates = clean_df["split"].eq("train") & clean_df["text_norm"].isin(other_split_texts)
cleaning_log.append({"op": "drop_train_texts_overlapping_validation_or_test", "removed": int(cross_split_duplicates.sum())})
clean_df = clean_df.loc[~cross_split_duplicates].reset_index(drop=True)
```

In [341…

```python
print("Data frame shape after cleaning:")
clean_df.groupby("split").size().rename("rows_after_cleaning").to_frame()
```

```
Data frame shape after cleaning:
```

Out[341…

	rows_after_cleaning
split	
test	722
train	5783
valid	723

In [342…

```python
import sys, sklearn

clean_df.to_parquet(ARTIFACTS / "polemo2_clean.parquet", index=False)

manifest = {
    "random_state": RANDOM_STATE,
    "source": "allegro/klej-polemo2-in",
    "source_urls": URLS,
    "label_map": LABEL_MAP,
    "classes": CLASSES,
    "split_sizes_raw": SPLIT_SIZES,
    "split_sizes_clean": {k: int(v) for k, v in clean_df["split"].value_counts().items()},
    "cleaning": cleaning_log,
    "parquet_sha256": hashlib.sha256((ARTIFACTS / "polemo2_clean.parquet").read_bytes()).hexdigest(),
    "versions": {"python": sys.version.split()[0], "pandas": pd.__version__, "sklearn": sklearn.__version__},
}
(ARTIFACTS / "splits.json").write_text(json.dumps(manifest, indent=2, ensure_ascii=False))
```

Out[342…

```
1202
```

Zadanie 10: Karta zbioru

Proszę stworzyć plik `dataset_card.md`. Proszę opisać zbiór tak, jakby dane miała przejąć jutro inna osoba w zespole.

Minimalna zawartość:

Dataset

Nazwa i źródło.

Task

Co próbujemy przewidywać / analizować?

Schema

Jakie kolumny mają dane?

Labels

Jakie są klasy?

Splits

Jak wykonano podział?

Data quality

Jakie problemy znaleziono?

Cleaning

Co zmieniono, a czego świadomie nie zmieniono?

Leakage audit

Czy znaleziono pokrywające się rekordy między splitami?

License / provenance

Skąd pochodzą dane i na jakiej licencji są udostępnione? Proszę porównać licencję w metadanych zbioru na Hugging Face z licencją w treści karty zbioru i zdecydować, którą przyjąć (i dlaczego). Proszę też sprawdzić tabelę rozkładu klas w karcie: czy nazwy sentymentu zgadzają się z danymi?

Limitations

Czego nie wolno wnioskować na podstawie tego zbioru?

Zacne przypadki porażek

Na każdych laboratoriach będziemy kolekcjonować przypadki, w których dane lub modele zachowują się niezgodnie z naszymi przewidywaniami, zabawnie, niewłaściwie.

Proszę znaleźć 3 takie wpisy we własnych wynikach; chodzi o rekordy, które są problematyczne, zaskakujące albo niejednoznaczne.

Dla każdego zapiszcie:

id	problem	tekst	dlaczego to ważne?
1	Opinie która zawierała jedną literę	P	Nie wiemy czy taka opinia to pomyła, czy celowy zabieg. Nie znamy intencji autora
2			
3			

Przykładowe problemy:

- label wydaje się dyskusyjny,
- bardzo krótki tekst,
- tekst zawiera kilka sprzecznych ocen,
- zdania duplikaty lub prawie duplikaty,
- nietypowa ortografia,
- ironia,
- tekst spoza oczekiwanej domeny.

Zadanie 11: Zadanie-Podsumowanie

A. Group leakage

Proszę zaproponować sytuację, w której teksty nie są identyczne, ale powinny należeć do tego samego splitu.

> Użytkownik napisał bardzo długą opinię, która została później podzielona na dwie części. Zapewne obie będą napisane w bardzo podobnym tonie, przez co model mógłby zacząć przyporządkowywać kategorie na podstawie stylu pisania zamiast rzeczywistej treści.

B. Temporal leakage

Załóżmy, że mamy timestampy. Proszę zaprojektować split użyteczny w prawdziwym wdrożeniu: uczymy na przeszłości, testujemy na przyszłości.

> Każdy rekord ma swój timestamp, a dodatkowo definiujemy sztywną datę graniczną, która oddziela zbiór testowy/walidacyjny od treningowego. Dzięki temu model nie „widzi przyszłości" już na etapie nauki, w przeciwnym wypadku model uczył by się na nierealnych sytuacjach tj. na podstawie przyszłości przewidywał by przeszłość.

C. Fingerprinting

Proszę zapisać SHA-256 znormalizowanego tekstu i przygotować mały manifest umożliwiający sprawdzanie overlapu między kolejnymi wersjami datasetu.

In [429…

```python
import hashlib
import json

all_df['fingerprint'] = all_df['text_norm'].apply(
    lambda x: hashlib.sha256(str(x).encode('utf-8')).hexdigest()
)

manifest = {
    split: all_df[all_df['split'] == split]['fingerprint'].tolist()
    for split in all_df['split'].unique()
}

with open("artifacts/dataset_manifest.json", "w", encoding="utf-8") as f:
    json.dump(manifest, f)
```

D. Near-duplicate benchmark

Proszę ręcznie ocenić 50 par wygenerowanych przez stworzony przez siebie detektor jako `duplicate / not_duplicate` i sprawdzić precision dla kilku progów podobieństwa. Pary należy losować z całego zakresu `sim ∈ [0.7, 1.0]` (np. po 10 z pięciu przedziałów), inaczej nie da się policzyć precision dla niższych progów. Proszę raportować `n` w każdym przedziale.

> Uwaga: to nie jest wyścig o najdłuższy kod. Najlepsze rozwiązanie to takie, którego założenia można w łatwy sposób obronić.

In [386…

```python
pd.set_option("display.max_colwidth", 16000)
pd.set_option("display.max_columns", 5000)
```

In [422…

```python
benchmark = []
```

In [423…

```python
benchmark.append({
    "batch": "90-100",
    "positive": 3, # [0,1,2]
    "negative": 0
})
find_pairs(all_df, j, sim, 0.9, 1).reset_index(drop=True)
```

Out[423…

	i	j	sim	cross_split	i_text	j_text
0	1344	6642	0.999948	True	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i Haemophilus influenzae . Poprawnie wykrywali śmy ich obecność w 95 proc . przypadków , a gatunek identyfikowali śmy z pewnością sięgającą 98 proc . A ponieważ mówimy o niezwykle czułej spektroskopii ramanowskiej , do otrzymania tak precyzyjnych wyników wystarczało nam znalezienie jednej komórki bakteryjnej " - podkreśla dr Kamińska . Cały przebieg analizy jest w znacznym stopniu zautomatyzowany i do minimum ogranicza kontakt laboranta z badaną próbką . W celu przeprowadzenia pomiaru należy jedynie pobrać pod wyciągiem laminarnym mikrolitrową porcję płynu mózgowo - rdzeniowego do strzykawki , a następnie tę umieścić w pompie strzykawkowej podłączonej do spektrometru Ramana . W celu zwiększenia pewności pomiaru zarejestrowane sygnały są przetwarzane przez oprogramowanie korzystające z zaawansowanych metod statystycznych i obsługującemu pozostaje jedynie odczytać wynik .	„ Przetestowali śmy nasze podłoża na trzech gatunkach bakterii wywołujących zapalenie opon mózgowych : Neisseria meningitidis , Streptococcus pneumoniae i Haemophilus influenzae . Poprawnie wykrywali śmy ich obecność w 95 proc . przypadków , a gatunek identyfikowali śmy z pewnością sięgającą 98 proc . A ponieważ mówimy o niezwykle czułej spektroskopii ramanowskiej , do otrzymania tak precyzyjnych wyników wystarczało nam znalezienie jednej komórki bakteryjnej ! " - podkreśla dr Kamińska . Cały przebieg analizy jest w znacznym stopniu zautomatyzowany i do minimum ogranicza kontakt laboranta z badaną próbką . W celu przeprowadzenia pomiaru należy jedynie pobrać pod wyciągiem laminarnym mikrolitrową porcję płynu mózgowo - rdzeniowego do strzykawki , a następnie tę umieścić w pompie strzykawkowej podłączonej do spektrometru Ramana . W celu zwiększenia pewności pomiaru zarejestrowane sygnały są przetwarzane przez oprogramowanie korzystające z zaawansowanych metod statystycznych i obsługującemu pozostaje jedynie odczytać wynik .

1	3413	5612	0.962757	False	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejednego małego 3 - gwiazdkowego hotelu „ gdzieś w Polsce ” . Czy 1 . 400 złotych „ na rękę ” z godzinami nocnymi i pracą w niedziele - za wykonywanie wszystkich powyższych prac to dużo czy mało ? Czy w hotelu 3 - gwazdkowym recepcjoniści w ogóle powinni wykonywać takie prace ? Odpowiedź na te pytania zależy od kilku warunków : jak duży jest hotel 3 - gwiazdkowy tzn . ile ma pokoi i innych stref ; gdzie jest położony , jak wysoka jest frekwencja , jak układa się sezonowość . I w końcu : jak podchodzimy do systemu rozliczania pracownika . 160 pokojowy hotel 3 - gwiazdkowy położony w centrum Warszawy , Wrocławia czy Poznania , w którym ruch gości i klientów trwa praktycznie od godziny 6 . 00 rano do 2 . 00 w nocy , gdzie średnio codziennie wynajęte jest 100 pokoi a w hotelu przebywa 120 - 150 gości - nie sposób porównać do 12 - 20 pokojowego hotelu wypoczynkowego , położonego w głębi województwa warmińsko - mazurskiego lub do miejskiego hotelu w niewielkim mieście powiatowym . Recepcjonista z dużego wielkomiejskiego hotelu a recepcjonista z małego , lokalnego hotelu - to dwóch różnych pracowników .	Powyższe jest spisem zadań , jakie na co dzień wykonują poza swoimi podstawowymi obowiązkami związanymi z obsługą gości w recepcji - recepcjoniści niejednego małego 3 - gwiazdkowego hotelu „ gdzieś w Polsce ” . Czy 1 . 400 złotych „ na rękę ” z godzinami nocnymi i pracą w niedziele - za wykonywanie wszystkich powyższych prac to dużo czy mało ? Czy w hotelu 3 - gwazdkowym recepcjoniści w ogóle powinni wykonywać takie prace ? Odpowiedź na te pytania zależy od kilku warunków : jak duży jest hotel 3 - gwiazdkowy tzn . ile ma pokoi i innych stref ; gdzie jest położony , jak wysoka jest frekwencja , jak układa się sezonowość . I w końcu : jak podchodzimy do systemu rozliczania pracownika . 160 pokojowy hotel 3 - gwiazdkowy położony w centrum Warszawy , Wrocławia czy Poznania , w którym ruch gości i klientów trwa praktycznie od godziny 6 . 00 rano do 2 . 00 w nocy , gdzie średnio codziennie wynajęte jest 100 pokoi a w hotelu przebywa 120 - 150 gości - nie sposób porównać do 12 - 20 pokojowego hotelu wypoczynkowego , położonego w głębi województwa warmińsko - mazurskiego lub do miejskiego hotelu w niewielkim mieście powiatowym .
2	3572	4360	0.943419	False	Wracając jednak do grupy hoteli dysponujących więcej niż tysiącem pokoi , na 9 pozycji znalazły się hotele należące do Wojskowej Agencji Mieszkaniowej . Grupa , która przez chwilę promowała się pod mało rozwojową nazwą Hotele 21 (miało być 21 obiektów , a nawet – wliczając np . niezrealizowany projekt hotelu dla NATO w Bydgoszczy – więcej) , praktycznie od kilku lat się nie rozwija . Nie można tego powiedzieć o Louvre Hotels Group , która wznosi dwa hotele we Wrocławiu oraz jest na „ pięć minut ” przez rozpoczęciem inwestycji w Bydgoszczy i Zielonej Górze . Dzięki umowie z deweloperską odnogą banku PKO BP , firmą Qualia Development , w ciągu siedmiu lat ma powstać siedem condohoteli pod marką Golden Tulip Residence z ok . tysiącem pokoi , które będą działały na podstawie umów franczyzowych . Pierwszy z obiektów , powinien zostać otwarty jeszcze w tym roku w Międzyzdrojach . Rok 2012 LHG powinna zatem zakończyć z ponad 1 , 5 tys . pokoi . , co ulokuje ją na 5 - 6 pozycji .	Grupa , która przez chwilę promowała się pod mało rozwojową nazwą Hotele 21 (miało być 21 obiektów , a nawet – wliczając np . niezrealizowany projekt hotelu dla NATO w Bydgoszczy – więcej) , praktycznie od kilku lat się nie rozwija . Nie można tego powiedzieć o Louvre Hotels Group , która wznosi dwa hotele we Wrocławiu oraz jest na „ pięć minut ” przez rozpoczęciem inwestycji w Bydgoszczy i Zielonej Górze . Dzięki umowie z deweloperską odnogą banku PKO BP , firmą Qualia Development , w ciągu siedmiu lat ma powstać siedem condohoteli pod marką Golden Tulip Residence z ok . tysiącem pokoi , które będą działały na podstawie umów franczyzowych . Pierwszy z obiektów , powinien zostać otwarty jeszcze w tym roku w Międzyzdrojach . Rok 2012 LHG powinna zatem zakończyć z ponad 1 , 5 tys . pokoi . , co ulokuje ją na 5 - 6 pozycji .

In [424…

```python
benchmark.append({
    "batch": "80-90",
    "positive": 0,
    "negative": 0
})
find_pairs(all_df, j, sim, 0.8, 0.9).reset_index(drop=True)
```

Out[424…

i	j	sim	cross_split	i_text	j_text

In [425…

```python
benchmark.append({
    "batch": "70-80",
    "positive": 2, # [0,3]
    "negative": 2 # [1,2]
})
find_pairs(all_df, j, sim, 0.7, 0.8).reset_index(drop=True)
```

Out[425…

	i	j	sim	cross_split	i_text	j_text
0	8	6581	0.786939	True	jest bardzo dobrym lekarzem miłu ciepły troszczy się o swoje pacjętki tylko , że ja chodze do niego w gdańsku i nie wiem czy to jest ten sam lekarz ``` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . ```	Bardzo dobry specjalista ``` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . `````` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . `````` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . ```
1	752	6597	0.718419	True	Częścią projektu jest również stworzenie zaawansowanego systemu informatycznego dla personelu medycznego i dla pacjentów . Będzie on zawierał jednolitą bazę danych klinicznych , genetycznych i molekularnych dotyczących dzieci z białaczką , jak również portal informacyjny dla pacjentów . Wartość dofinansowania to ponad 13 , 5 mln zł . Strategmed to strategiczny program badań naukowych i prac rozwojowych , który został opracowany przez Radę Narodowego Centrum Badań i Rozwoju na podstawie Krajowego Programu Badań . Dokument określił strategiczne dla państwa kierunki badań naukowych i prac rozwojowych , a choroby cywilizacyjne zdefiniował jako największe zagrożenie zdrowotne dla populacji Polski w perspektywie najbliższych lat . Na liście chorób cywilizacyjnych znalazły się m . in . choroby układu krążenia , nowotwory złośliwe , a także choroby psychiczne .	W projekcie oprócz Śląskiego Uniwersytetu Medycznego biorą udział : Warszawski Uniwersytet Medyczny , Instytut Biologii Doświadczalnej im . M . Nenckiego PAN w Warszawie , Akademia Górniczo - Hutnicza w Krakowie , Regionalne Centrum Naukowo - Technologiczne w Podzamczu pod Kielcami oraz prywatna firma , która ma odpowiadać za wdrożenie wypracowanych rozwiązań . Strategmed to strategiczny program badań naukowych i prac rozwojowych , który został opracowany przez Radę Narodowego Centrum Badań i Rozwoju na podstawie Krajowego Programu Badań . Dokument określił strategiczne dla państwa kierunki badań naukowych i prac rozwojowych , a choroby cywilizacyjne zdefiniował jako największe zagrożenie zdrowotne dla populacji Polski w perspektywie najbliższych lat . Na liście chorób cywilizacyjnych znalazły się m . in . choroby układu krążenia , nowotwory złośliwe , a także choroby psychiczne .
2	2061	2596	0.704871	False	Operacje wszczepienia stymulatorów polegają na otwarciu kanału kręgowego , a następnie wprowadzeniu elektrody nad oponę twardą rdzenia kręgowego . Do tej elektrody przepływa prąd ze stymulatora , który jest umieszczony na tułowiu pacjenta . Prąd ze stymulatora poprzez elektrodę ma efektywnie drażnić struktury pnia mózgu . Stymulator z elektrodą połączony jest przebiegającym pod skórą przewodem . Stymulator co 15 minut wysyła " porcję prądu " do mózgu . Prof . Maksymowicz tłumaczył wcześniej PAP , że ma to wpłynąć na zwiększenie przepływu mózgowego tak , żeby było więcej odżywczej krwi , " żeby te neurony , które przetrwały u chorych urazy , poczuły się lepiej , były lepiej odżywione ” . Zwiększenie przepływu mózgowego i stymulacja mózgu ma w konsekwencji doprowadzić do nawiązania kontaktu z osobami , które dotąd były w stanie minimalnej świadomości .	Pionierskie operacje wszczepienia stymulatorów osobom w śpiączkach w maju przeprowadził w olsztyńskim szpitalu klinicznym zespół prof . Wojciecha Maksymowicza pod kierunkiem japońskiego neurochirurga prof . Isao Morita (przeprowadził on w Japonii ok . 300 tego rodzaju operacji) . Prof . Moritę sprowadziła do Polski Fundacja Ewy Błaszczyk " Akogo ? " , stymulatory dla chorych nieodpłatnie przekazał ich producent - Boston Scientific Polska . Operacje polegają na otwarciu kanału kręgowego , a następnie wprowadzeniu elektrody nad oponę twardą rdzenia kręgowego . Do tej elektrody przepływa prąd ze stymulatora , który jest umieszczany na tułowiu pacjentów . Prąd ze stymulatora poprzez elektrodę ma efektywnie drażnić struktury pnia mózgu . Stymulator z elektrodą połączony jest przebiegającym pod skórą przewodem .
3	3918	6285	0.740676	True	Hotel generalnie ok . Czysto i to wystarczy . Pokój przestronny . WiFi działa przyzwoicie . Śniadania w formie szwedzkiego stołu trochę ubogie . Parking dodatkowo płatny . Z basenu i innych atrakcji nie korzystał em więc nie będę o nich pisać . Na jedną noc , biznesowo mogę polecić . Pozdrawiam	Hotel generalnie ok . Czysto i to wystarczy . Pokoje nawet przestronne , a w niektórych klimatyzacja . WiFi dziala przyzwoicie . Śniadania w formie szwedzkiego stołu trochę ubogie ale niech będzie . Parking dodatkowo płatny . Bliskość centrum niewątpliwie atutem . Na jedną noc , biznesowo mogę polecić . Pozdrawiam

In [426…

```python
benchmark.append({
    "batch": "60-70",
    "positive": 4, # [2,3,4,5]
    "negative": 3 # [0,1,6]
})
find_pairs(all_df, j, sim, 0.6, 0.7).reset_index(drop=True)
```

Out[426…

	i	j	sim	cross_split	i_text	j_text
0	89	6581	0.629975	True	skierował mnie do tego gabinetu moj dentysta gdy miał problem z jednym moim zębem podczas leczenia kanałowego , wąskie kanały , zakrzywione , powiedział że On może tylko wyrwać mi go . zapisała m się do jednego z dwóch braci Sypień . kosmos . pełny profesjonalizm . ząb uratowany ! Dzięki ! ``` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . ```	Bardzo dobry specjalista ``` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . `````` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . `````` Ocena została zmieniona na " Polecam " . Powód : Zbyt lakoniczna argumentacja do wystawienia najwyższej oceny . ```
1	127	6009	0.640627	True	Zespół z PŁ za pomocą drukarki nanosi na powierzchnię włókniny czy tkaniny elektroprzewodzący atrament - w którego skład mogą wchodzić np . związki srebra - i odpowiednio go aktywuje . Dzięki temu rozwiązaniu elektrody dobrze przylegają do skóry , a użytkownik nie ma problemu z ich nakładaniem i zdejmowaniem . Poza tym z ubrań nie wystają żadne części elektrod , a to bywało problemem w przypadku innych sposobów łączenia elektrod z ubraniami . Jak zaznacza prof . Krzysztof Gniotek , takie tekstylne elektrody można było by stosować np . w ortezach (stosowanych przy uszkodzeniach stawów) , w skarpetkach czy w ściągaczach koszulek . Najważniejszym zastosowaniem elektrod było by ich wykorzystanie w elektroterapii - tam elektrody muszą pozostawać na ciele pacjenta przez dłuższy czas , więc ukrycie ich w ubraniu mogło by być dla użytkownika bardziej komfortowe .	" Elektrody przydają się np . wówczas , kiedy trzeba zebrać informacje o potencjałach elektrycznych ze skóry człowieka lub kiedy chcemy na organizm oddziaływać impulsami elektrycznymi " - obrazuje prof . Krzysztof Gniotek z Katedry Odzieżownictwa i Tekstroniki Politechniki Łódzkiej - kierownik zespołu , który pracuje nad tekstylnymi elektrodami . Dodaje , że elektrody przydają się np . w badaniu EKG lub w czasie elektroterapii , która polega na stymulowaniu pacjenta odpowiednio dobranym prądem elektrycznym o niskim natężeniu . Dotychczas w Polsce na potrzeby medycyny było dostępnych niewiele rodzajów elektrod , m . in . płytki metalowe czy elektrody żelowe . " My opracowujemy elektrody nanoszone na elementy ubrań , bo przecież noszenie ubrań jest dla nas czymś naturalnym " - wyjaśnia prof . Gniotek . Naukowiec przyznaje , że na polskim rynku już są dostępne np . skarpetki z elektrodami . Ale w odróżnieniu od rozwiązania łodzian , nie są to elektrody nadrukowane na ubrania .

2	392	1193	0.655872	False	" Metoda wypracowana przez Macieja Wojtkowskiego (FD - OCT) zmieniła kierunek badań współczesnej okulistyki , a przy tym – wywarła ogromny wpływ na rozwój metod i procedur klinicznych , i co za tym idzie – na komfort pacjentów i jakość danych dostępnych lekarzom na całym świecie . Jego praca badawcza jest rzadkim przykładem pracy teoretycznej i doświadczalnej z fizyki , która w krótkim czasie znalazła zastosowania w praktyce i doprowadziła do produkcji nowych urządzeń diagnostycznych " – czytamy komunikacie FNP . W ciągu kilku lat od zaproponowania metody FD - OCT praktycznie wyparła ona wcześniejszą technologię diagnostyki stanów chorobowych siatkówki i stała się podstawą dla produkcji aparatury medycznej . Tomografy optyczne oparte na tej technologii używane są w klinikach w całej Polsce oraz sprzedawane na całym świecie .	Nie ulega jednak wątpliwości , że metoda wypracowana przez Macieja Wojtkowskiego dla okulistyki wywarła ogromny wpływ na rozwój procedur klinicznych , na komfort pacjentów i jakość danych dostępnych lekarzom na całym świecie . Radykalnie poprawiła szybkość i rozdzielczość analizy do poziomu niemożliwego do uzyskania wcześniej w warunkach klinicznych . W ciągu kilku lat od zaproponowania praktycznie wyparła wcześniejszą technologię diagnostyki stanów chorobowych siatkówki . Stała się podstawą dla produkcji aparatury medycznej o wartości 1 mld dolarów w Stanach Zjednoczonych i kolejnego 1 mld dolarów w innych krajach . Tomografy optyczne oparte na tej technologii produkowane są także w Zawierciu i używane w klinikach w całej Polsce oraz sprzedawane na całym świecie . PAP – Nauka w Polsce , Karolina Olszewska
3	2729	4640	0.654241	False	W lipcu 2012 r . w bazie Głównego Urzędu Statystycznego było zarejestrowanych 7177 obiektów zbiorowego zakwaterowania . To o 1 , 96 proc . obiektów więcej niż rok wcześniej . Łącznie obiekty te oferowały miejsc noclegowych , czyli o 3 , 39 proc . więcej niż w lipcu 2011 r . , wynika z przedstawionej właśnie informacji Głównego Urzędu Statystycznego „ Baza noclegowa wg stanu w dniu 31 lipca oraz jej wykorzystanie w I półroczu 2012 roku ” . Najliczniejszą grupę wśród obiektów zbiorowego zakwaterowania stanowiły obiekty hotelowe , których było 3 414 . Natomiast najliczniejszą grupę wśród obiektów hotelowych , podobnie jak w latach poprzednich stanowiły hotele , których GUS odnotował 2 014 , tj . o 7 proc . więcej w stosunku do 2011 r . , gdy GUS odnotował 1 883 hotele . Drugą grupą , pod względem wielkości zasobów , były inne obiekty hotelowe , których było 1 400 .	7 039 obiektów zbiorowego zakwaterowania , w których znajdowało się 606 , 2 tys . miejsc noclegowych było zarejestrowanych w Polsce 31 lipca 2011 r . W porównaniu do roku 2010 liczba obiektów zbiorowego zakwaterowania zmniejszyła się o 167 tj . o 2 , 3 proc . obiektów zaś liczba miejsc noclegowych o 3 , 9 tys . , czyli o 0 , 6 proc , wynika z najnowszego opublikowanego w połowie sierpnia opracowania „ Turystyka w 211 r . ” , przygotowanego przez Główny Urząd Statystyczny . Baza noclegowa objęta badaniem GUS dotyczy 18 rodzajów obiektów zbiorowego zakwaterowania , spośród których 3 285 to obiekty hotelowe , zaś 3754 to pozostałe obiekty zbiorowego zakwaterowania . Wśród obiektów hotelowych najliczniejszą grupę stanowiły hotele – 1 883 obiektów , zaś wśród pozostałych obiektów najwięcej było ośrodków wczasowych – 1 080 .
4	3337	4448	0.631446	False	Śniadanie będzie wliczone w cenę pokoju . Będą również pokoje dla niepełnosprawnych . Nie zabraknie miejsc parkingowych dla podróżujących samochodem . Budowa Hampton by Hilton Warsaw Airport zlokalizowana jest w odległości około 800 m od terminalu pasażerskiego Lotniska Chopina w Warszawie , u zbiegu ulicy 17 Stycznia oraz ulicy Żwirki i Wigury . Natomiast Hampton by Hilton Gdańsk Airport powstanie naprzeciwko nowego terminalu Lotniska im . Lecha Wałęsy w Gdańsku Rębiechowie , który jest jednym z najnowocześniejszych terminali lotniskowych w naszym kraju . Zdjęcia : Lokalizacja hotelu Hampton by Hilton w Warszawie – widok z hoteli Courtyard by Marriott , którego operatorem jest spółka Port - Hotel ; w lewym dolnym rogu fragment budowy hotelu Renaissance by Marriott , którego operatorem również będzie Port - Hotel ; w centralnym punkcie zdjęcia hotel Gromada Okęcie , po prawej Airport Hotel Okęcie . Hotel Hampton by Hilton w Gdańsku na wizualizacjach : hol główny , sala śniadaniowa , strefa pracy .	Planowana inwestycja zlokalizowana jest w odległości około 800 m od terminalu pasażerskiego Lotniska Chopina w Warszawie . Natomiast Hampton by Hilton Gdańsk Airport powstanie naprzeciwko budowanego obecnie głównego terminalu Lotniska im . Lecha Wałęsy w Gdańsku Rębiechowie . Spółka Port - Hotel została założona w roku 1998 przez Przedsiębiorstwo Państwowe „ Porty Lotnicze ” . Celem działań Port - Hotel jest realizacja programu budowy nowych hoteli w wybranych lokalizacjach w Polsce , z uwzględnieniem lokalizacji przy lotniskach i w centrach miast , a także zarządzanie hotelami . Pierwszym projektem zrealizowanym przez Spółkę był czterogwiazdkowy hotel Courtyard by Marriott Warsaw Airport przy Lotnisku Chopina w Warszawie , którego Spółka jest jednocześnie właścicielem .
5	4877	6214	0.632261	True	Obiekty , zlokalizowane w Pekinie , Szanghaju i sześciu innych , wschodzących miastach biznesowych , w sumie będą miały niemal 2 , 8 tys . pokoi . Hotele przyjmą pierwszych gości w latach 2014 - 2016 , ich właścicielami są inwestorzy , którzy podejmują współpracę z IHG po raz pierwszy . Wspomniane osiem hoteli Hualuxe Hotels and Resort znajduje się w miastach , w których IHG posiada już działające lub znajdujące się w budowie hotele i na tych rynkach nowa marka będzie uzupełniała ich ofertę . Hotele marki Hualuxe Hotels and Resorts są kluczowym elementem strategii wzrostu IHG w Chinach . W pierwszej fazie mają być otwierane w miastach 1 , 2 i 3 kategorii i miejscowościach wypoczynkowych . IHG widzi możliwość powstania tych hoteli w ponad 100 miastach w Chinach w ciągu najbliższych 15 - 20 lat . Hotele , na które zostały już podpisane umowy to : - Hualuxe Beijing Xinan : 380 pokoi , - Hualuxe Shanghai Pudong Kangqiao : 400 pokoi , - Hualuxe Chengdu High - Tech West : 350 pokoi , - Hualuxe Zhangjiajie Resort : 380 pokoi , - Hualuxe Ordos Dongsheng : 300 pokoi , - Hualuxe Foshan Nanhai : 350 pokoi , - Hualuxe Yangjiang City Centre : 282 pokoje , - Hualuxe Fuzhou Downtown : 330 pokoi .	Osiem umów o zarządzanie hotelami nowej , stworzonej specjalnie na rynek chiński , marki Hualuxe Hotels and Resorts , podpisała w ciągu pięciu miesięcy od startu projektu , sieć InterContinental Hotels Group . Obiekty , zlokalizowane w Pekinie , Szanghaju i sześciu innych , wschodzących miastach biznesowych , w sumie będą miały niemal 2 , 8 tys . pokoi . Hotele przyjmą pierwszych gości w latach 2014 - 2016 , ich właścicielami są inwestorzy , którzy podejmują współpracę z IHG po raz pierwszy . Wspomniane osiem hoteli Hualuxe Hotels and Resort znajduje się w miastach , w których IHG posiada już działające lub znajdujące się w budowie hotele i na tych rynkach nowa marka będzie uzupełniała ich ofertę .
6	5725	6766	0.623755	True	Na lokalizację wskazało 74 proc . kobiet i 65 proc . ankietowanych mężczyzn ; w przypadku łóżka wybór rozkładał się na 78 proc . kobiet i 70 proc . mężczyzn . Dla mężczyzn ważniejsze były jednak trzy kolejne kryteria o wyborze hotelu : cena , darmowy Internet i wcześniejszy pobyt w wybieranym obiekcie . W sumie na cenę wskazało 52 proc . badanych (54 proc . mężczyzn i 44 proc . kobiet) , na darmowy internet 46 proc . (48 proc . mężczyzn i 37 proc . kobiet) , zaś na wybranie obiektu , w którym już wcześniej nocowali także 46 proc . badanych (48 proc . mężczyzn i 34 proc . kobiet) . Na kolejnych miejscach wśród pięciu najważniejszych usług hotelowych znalazły się : odpowiednie wyposażenie łazienki (50 proc .) , uprzejmy personel (36 proc .) , darmowy Internet (35 proc .) i profesjonalizm personelu hotelowego (27 proc .) . Natomiast spośród usług , których podróżujący biznesmeni oczekiwali by od obiektów noclegowych na czele znalazły się : media z kraju gościa , takie jak gazety i kanały telewizyjne (60 proc .) oraz dedykowany uczestnikom programu lojalnościowego system obsługi (50 proc .) . Badanie „ Accor Business Traveler Survey 2012 ” pokazuje także różnice między podróżnymi z Francji , Niemiec i Wielkiej Brytanii .	Najchętniej warzywa i owoce jemy surowe lub gotowane , jednak preferencje są dość zróżnicowane . Kobiety częściej niż mężczyźni wybierają stosunkowo „ egzotyczne ” formy przyrządzania warzyw i owoców : duszenie (31 proc . kobiet i 26 proc . mężczyzn) , parowanie (28 proc . kobiet i 19 proc . mężczyzn) , pieczenie (24 proc . kobiet i 15 proc . mężczyzn) i grillowanie (24 proc . kobiet i 12 proc . mężczyzn) . Również kobiety (77 proc .) częściej niż mężczyźni (69 proc .) jedzą warzywa i owoce jako samodzielne potrawy , np . w postaci przekąsek . Jeszcze większą dysproporcję można zaobserwować w przypadku spożywania warzyw i owoców jako dodatku do innych potraw , np . w formie surówki lub sałatki . Spożywa je w ten w sposób aż 88 proc . kobiet i 75 proc . mężczyzn .

In [427…

```
benchmark_df = pd.DataFrame(benchmark)
benchmark_df
```

Out[427…

	batch	positive	negative
0	90-100	3	0
1	80-90	0	0
2	70-80	2	2
3	60-70	4	3

Raport końcowy

Na końcu notebooka proszę wpisać pięć najważniejszych wniosków. Każdy punkt ma być obserwacją o danych lub metodologii.

Warunki ukończenia laboratorium

Laboratorium jest skończone, jeśli raport zawiera:

- ☑ sanity check wszystkich splitów;
- ☑ rozkład klas;
- ☑ analizę długości;
- ☑ status zaszumienia;
- ☑ status duplikatów;
- ☑ `audit_split_leakage(...)` ;
- ☑ eksperyment z wykrywaniem zdań z pogranicza duplikatów;
- ☑ porównanie oficjalnego i losowego splitu;
- ☑ kontrolowany eksperyment z wyciekiem danych pomiędzy zbiorami;
- ☑ `artifacts/polemo2_clean.parquet` ;
- ☑ `artifacts/splits.json` ;
- ☑ `dataset_card.md` ;
- ☐ przykłady pomyłek;
- ☐ obserwacje końcowe.